

UNIwersytet Ekonomiczny w Katowicach

INFORMATYKA

RAFAŁ BANAŚ

152863

**MODEL PREDYKCJI FORMY KOLARSKIEJ OPARTY
NA DANYCH TELEMETRYCZNYCH Z URZĄDZEŃ
SPORTOWYCH Z WYKORZYSTANIEM UCZENIA
MASZYNOWEGO**

**A MACHINE LEARNING-BASED MODEL FOR PREDICTING CYCLING
PERFORMANCE USING TELEMETRY DATA FROM SPORTS DEVICES**

Praca magisterska napisana
pod kierunkiem dr Barbary Probiecz

KATOWICE 2026

OŚWIADCZENIE PROMOTORA

Oświadczam, że niniejsza praca została przygotowana pod moim kierunkiem i stwierdzam, że spełnia wymogi stawiane pracom dyplomowym.

Pracę akceptuję

.....

(data)

.....

(podpis promotora)

Rafał Banaś

Katowice, dnia 14 czerwca 2026 r.

.....
Imię i nazwisko

Informatyka

.....
Kierunek

152863

.....
Nr albumu

OŚWIADCZENIE

Mając świadomość odpowiedzialności prawnej oświadczam, że złożona praca magisterska pt.

.....
Model predykcji formy kolarskiej oparty na danych telemetrycznych z urządzeń sportowych z wykorzystaniem uczenia maszynowego

.....
została napisana przeze mnie samodzielnie. Równocześnie oświadczam, że praca ta nie narusza praw autorskich w rozumieniu ustawy z dnia 4 lutego 1994 roku o prawie autorskim i prawach pokrewnych oraz dóbr osobistych chronionych prawem. Ponadto praca nie zawiera informacji i danych uzyskanych w sposób niedozwolony i nie była wcześniej przedmiotem innych procedur związanych z uzyskaniem dyplomów lub tytułów zawodowych uczelni wyższej. Wyrażam zgodę na nieodpłatne udostępnienie mojej pracy w celu oceny jej oryginalności przez Jednolity System Antyplagiatowy prowadzony przez ministra właściwego ds. szkolnictwa wyższego oraz przechowywania jej w Ogólnopolskim Repozytorium Prac Dyplomowych oraz wewnętrznej bazie prac dyplomowych Uniwersytetu Ekonomicznego w Katowicach. Oświadczam, że poinformowano mnie o zasadach dotyczących oceny oryginalności pracy dyplomowej przez Jednolity System Antyplagiatowy. Oświadczam także, że ostateczna wersja pracy przesłana przeze mnie drogą elektroniczną jest zgodna z plikiem poddanym ocenie w Jednolitym Systemie Antyplagiatowym. Jednocześnie oświadczam, że jest mi znany przepis art. 233 § 1 Kodeksu karnego określający odpowiedzialność za składanie fałszywych zeznań.

.....
(podpis składającego oświadczenie)

Spis treści

Wstęp	6
Rozdział 1. FTP jako parametr wydolności	8
1.1 Definicja Functional Threshold Power	8
1.2 Pomiar mocy w kolarstwie	10
1.3 Znaczenie pomiaru mocy w treningu kolarskim	12
1.4 Znaczenie FTP w praktyce treningowej	13
1.5 Podstawy fizjologii wysiłku istotne dla interpretacji FTP	14
1.6 Test 20-minutowy – przebieg i ilustracja	16
1.7 Test 60-minutowy – przebieg i ilustracja	18
1.8 Krzywa mocy i zależność FTP od czasu trwania wysiłku	19
1.9 Charakterystyka danych treningowych	20
1.10 Klasyczne podejścia a uczenie maszynowe w szacowaniu FTP	22
1.11 Zarys procesu przetwarzania danych i budowy modelu	26
1.12 Przegląd badań naukowych i istniejących rozwiązań	28
1.12.1 Badania nad FTP i mocą krytyczną	28
1.12.2 Uczenie maszynowe w analizie telemetrii sportowej	29
1.12.3 Istniejące systemy analityczne	31
1.12.4 Wykorzystane technologie i narzędzia	32
1.13 Podsumowanie części teoretycznej	33
Rozdział 2. Metodologia badań i projekt rozwiązania	34
2.1 Architektura potoku przetwarzania	34
2.2 Charakterystyka źródeł danych	36
2.3 Przygotowanie danych	38
2.4 Definicja zmiennej celu i etykietowanie	39
2.5 Inżynieria cech	41
2.6 Warianty eksperymentalne	42
2.7 Strategia podziału danych	43
2.8 Modele i metryki oceny	44

2.9 Wykorzystane technologie i narzędzia	45
2.10 Podsumowanie	45
Rozdział 3. Eksperymenty i wyniki	47
3.1 Charakterystyka przygotowanego zbioru danych	47
3.2 Konfiguracja eksperymentu i podział danych	48
3.3 Przebieg eksperymentów, modele i parametry	49
3.4 Wyniki predykcji dla wariantów A, B i C	51
3.5 Porównanie i interpretacja modeli	51
3.6 Analiza rozkładu błędów	54
3.7 Znaczenie i ważność cech predykcyjnych	56
3.8 Dodatkowa próba kontrolna skalowalności	61
3.9 Podsumowanie uzyskanych rezultatów	66
Rozdział 4. Ocena rozwiązania, zastosowanie praktyczne i dyskusja . . .	68
4.1 Interpretacja uzyskanych wyników	68
4.2 Ocena rozwiązania w kontekście postawionych celów	69
4.3 Znaczenie uczenia maszynowego w estymacji FTP	69
4.4 Ograniczenia przeprowadzonego badania	70
4.5 Praktyczne możliwości zastosowania	72
4.5.1 Koncepcja modułu wspierającego platformę treningową	72
4.5.2 Perspektywa zawodnika	74
4.5.3 Perspektywa trenera	74
4.5.4 Perspektywa platformy analitycznej	74
4.6 Ryzyka wdrożenia i komunikowanie niepewności	75
Zakończenie	76
Bibliografia	79
Netografia	85
Spis rysunków	86
Spis tabel	87

Wstęp

Rozwój mierników mocy, czujników tętna i platform treningowych umożliwia systematyczne gromadzenie danych z codziennych aktywności kolarskich. Dane te mogą uzupełniać okresowe testy wydolnościowe, które są obciążające i trudne do częstego powtarzania. Problem badawczy podjęty w pracy dotyczy możliwości estymacji Functional Threshold Power (FTP) na podstawie zagregowanej telemetrii z rutynowych jazd, bez wykorzystywania cech bezpośrednio odtwarzających sposób wyznaczenia wartości referencyjnej.

FTP jest w pracy traktowane jako operacyjny wskaźnik dyspozycji wytrzymałościowej, a nie pełna miara formy sportowej ani odpowiednik proggu zmierzonego laboratoryjnie. Wartość referencyjną stanowi heurystyczna etykieta obliczona jako 95% maksymalnej średniej mocy z 20 minut. Przyjęcie takiej definicji umożliwia ilościową ocenę modeli, ale ogranicza zakres interpretacji wyników.

Sformułowano następującą hipotezę badawczą:

Co najmniej jeden model regresyjny wykorzystujący zagregowane cechy telemetryczne, z wyłączeniem całej rodziny cech Maximum Mean Power (mmp_), osiągnie na zbiorze testowym obejmującym zawodników nieobecnych w zbiorze uczącym błąd MAE nie większy niż 15 W oraz współczynnik determinacji R^2 nie mniejszy niż 0,80 w estymacji operacyjnej etykiety FTP.*

Celem głównym pracy jest zaprojektowanie, implementacja i ewaluacja prototypowego systemu analitycznego do estymacji operacyjnej etykiety FTP. Cel poznawczy obejmuje usystematyzowanie wiedzy o FTP i analizie telemetrii kolarskiej. Celem metodologicznym jest przygotowanie powtarzalnego potoku przetwarzania danych i rzetelnej procedury oceny modeli z kontrolą data leakage. Cel użytkowy polega na ocenie, czy wynik modelu może stanowić dodatkową informację w monitorowaniu zmian FTP.

Badanie odpowiada na następujące pytania:

1. Czy modele uczone bez cech mmp_* spełniają przyjęte kryteria jakości na danych zawodników nieobecnych w zbiorze uczącym?

2. Który z algorytmów: Ridge Regression, Random Forest i XGBoost, osiąga najlepsze wartości MAE, RMSE i R^2 ?
3. Jak zmienia się jakość predykcji po usunięciu cechy `mmp_20min`, a następnie całej rodziny cech `mmp_*`?
4. Które grupy cech mają największe znaczenie dla predykcji?

Zakres przedmiotowy obejmuje przetwarzanie telemetrii kolarskiej, inżynierię cech i regresyjną estymację FTP. Zakres podmiotowy tworzą anonimowi użytkownicy repozytorium GoldenCheetah OpenData. Zbiór bazowy przygotowany z 781 archiwów ZIP obejmuje po filtracji 151 399 sesji 726 zawodników. Zakres czasowy wyznaczają historyczne aktywności dostępne w wersji repozytorium pozyskanej do badania, a zakres przestrzenny ma charakter międzynarodowy i wynika ze struktury tego repozytorium.

Zastosowano analizę literatury, przygotowanie potoku Extract–Transform–Load, inżynierię cech oraz eksperyment porównawczy modeli Ridge Regression, Random Forest i XGBoost. Dane podzielono na poziomie zawodników z użyciem `GroupShuffleSplit`, a jakość oceniono metrykami MAE, RMSE, MedAE i R^2 . Wariant kontrolny A zawierał `mmp_20min`, wariant B wykluczał tę cechę, a wariant C wykluczał wszystkie cechy `mmp_*`.

Praca składa się z czterech rozdziałów merytorycznych. Rozdział pierwszy przedstawia podstawy teoretyczne i przegląd literatury. Rozdział drugi opisuje metodologię oraz projekt rozwiązania, trzeci prezentuje eksperymenty i wyniki, a rozdział czwarty zawiera ocenę rozwiązania, ograniczenia oraz możliwości praktycznego zastosowania wyników. Zakończenie podsumowuje wyniki i weryfikuje hipotezę.

Podstawę literaturową stanowią publikacje dotyczące treningu z pomiarem mocy, wiarygodności FTP, fizjologii wysiłku oraz zastosowań uczenia maszynowego i zasad rzetelnej walidacji modeli (Allen i in., 2019; Borszcz i in., 2018; Karsten i in., 2021; Stockwell i Corradini, 2023; Denham i in., 2020; James i in., 2021; Hastie i in., 2009). Dane empiryczne pochodzą z repozytorium GoldenCheetah OpenData (Liversedge, 2020).

Rozdział 1. FTP jako parametr wydolności

Rozdział tworzy podstawę pojęciową dla dalszej części pracy. Wyjaśnia, czym jest Functional Threshold Power (FTP), jaką rolę odgrywa w treningu kolarskim oraz dlaczego może być estymowany na podstawie danych z rutynowych aktywności.

Wydolność tlenowa jest jednym z kluczowych czynników wpływających na wynik sportowy w kolarstwie (Borszcz i in., 2018). W praktyce potrzebne są wskaźniki, które opisują możliwości zawodnika, a jednocześnie mogą być regularnie obserwowane poza laboratorium. Jednym z najczęściej stosowanych parametrów jest FTP, czyli praktyczny wskaźnik progu wysiłkowego (Borszcz i in., 2018; Allen i in., 2019; Gavin i in., 2012).

W kolejnych częściach przedstawiono charakterystykę danych treningowych, klasyczne i oparte na uczeniu maszynowym metody szacowania parametrów wydolnościowych oraz przegląd badań i istniejących rozwiązań. Pozwala to uzasadnić dobór zmiennej celu, cech telemetrycznych i procedury oceny zastosowanej w części empirycznej.

Functional Threshold Power (FTP) jest jednym z najczęściej stosowanych w praktyce treningowej wskaźników wydolności tlenowej kolarzy (Borszcz i in., 2018; Allen i in., 2019). Intuicyjnie można go opisać jako „moc, którą kolarz jest w stanie utrzymać przez dłuższy czas bez narastającego, gwałtownego zmęczenia”. W przeciwieństwie do prostych wartości maksymalnych (np. maksymalnej mocy szczytowej czy tętna maksymalnego), FTP odnosi się do zdolności organizmu do długotrwałego utrzymania wysokiej, ale jeszcze zrównoważonej intensywności wysiłku. Z tego powodu parametr ten dobrze nadaje się do opisu poziomu sportowego i planowania treningu wytrzymałościowego.

1.1. Definicja Functional Threshold Power

W literaturze związanej z treningiem kolarskim parametr FTP najczęściej definiuje się jako najwyższą wartość mocy, jaką kolarz jest w stanie utrzymać w stanie quasi-stacjonarnym przez około 60 minut (Borszcz i in., 2018; Allen i in., 2019). „Quasi-stacjonarny” oznacza tutaj, że reakcja fizjologiczna organizmu (w szczególności tętno, wentylacja oraz stężenie mleczanu we krwi) stabilizują się na podwyższonym, ale względnie stałym poziomie. W praktyce przyjmuje się, że przy mocy równej FTP

parametry te nie narastają już gwałtownie, natomiast przekroczenie tej intensywności prowadzi do szybkiego narastania zmęczenia i konieczności zredukowania mocy (Borszcz i in., 2018; Karsten i in., 2021).

Ze względów praktycznych FTP rzadko wyznacza się z pełnego, 60-minutowego testu czasowego. Taki test jest bardzo obciążający, wymaga odpowiednich warunków i trudno go często powtarzać. Dlatego w treningu amatorskim i zawodowym spopularyzowały się krótsze protokoły, z których najpopularniejszy jest 20-minutowy test maksymalny (Allen i in., 2019). Uproszczona wersja polega na wykonaniu rozgrzewki, a następnie jeździe z maksymalnym możliwym wysiłkiem przez 20 minut. Średnia moc z tego odcinka jest następnie mnożona przez współczynnik (najczęściej 0,95), co ma przybliżać moc, jaką kolarz byłby w stanie utrzymać przez 60 minut (Allen i in., 2019; Sitko i in., 2023; Inglis i in., 2020).

$$FTP \approx 0,95 \cdot \overline{P}_{20 \text{ min}}, \quad (1.1)$$

gdzie $\overline{P}_{20 \text{ min}}$ oznacza średnią moc w 20-minutowym odcinku testowym.

Współczynnik 0,95 należy traktować jako praktyczną heurystykę, a nie jako uniwersalne prawo fizjologiczne. Różnica pomiędzy maksymalną mocą możliwą do utrzymania przez 20 i 60 minut zależy między innymi od profilu zawodnika, poziomu wytrenowania, zdolności do wysiłków o dużej intensywności oraz umiejętności rozłożenia tempa. Kolarz o relatywnie silnym komponencie beztlenowym może osiągnąć bardzo dobry wynik krótszej próby, który po prostym przemnożeniu będzie przewyższał wartość odpowiadającą wysiłkowi godzinnemu. U innej osoby relacja może być bliższa przyjętemu przelicznikowi. Zmienność tę opisują badania porównujące próby 20- i 60-minutowe (Sitko i in., 2023; Gough i in., 2025).

Warto podkreślić, że jest to definicja funkcjonalna, a nie „fizjologiczna” w ścisłym sensie. FTP nie jest bezpośrednim pomiarem żadnego pojedynczego mechanizmu w organizmie (np. maksymalnego poboru tlenu), lecz wygodnym parametrem łączącym w sobie kilka aspektów wydolności: zdolność do generowania mocy, tolerancję zmęczenia i efektywność procesów metabolicznych (Borszcz i in., 2018; Karsten i in., 2021).

W tym miejscu konieczne jest rozróżnienie kilku pojęć stosowanych w diagnostyce wysiłkowej. Critical Power (CP) jest parametrem modelu matematycznego opisującego

relację pomiędzy możliwą do utrzymania mocą a czasem wysiłku. Maximal Lactate Steady State (MLSS) odnosi się natomiast do najwyższej intensywności, przy której stężenie mleczanu może pozostawać względnie stabilne podczas wysiłku ciągłego. Progi mleczanowe (LT_1 , LT_2) i wentylacyjne (VT_1 , VT_2) są wyznaczane na podstawie zmian odpowiednio stężenia mleczanu lub parametrów oddechowych podczas próby o narastającym obciążeniu. Wszystkie te wskaźniki opisują obszar przemian energetycznych istotny dla wysiłku wytrzymałościowego, lecz nie są synonimami FTP (Jones i in., 2019; Borszcz i in., 2018; Karsten i in., 2021; McGrath i in., 2021; Jeffries i in., 2021; Caen i in., 2024; Chorley i Lamb, 2020; Galán-Rioja i in., 2020).

Różnica ma znaczenie praktyczne. Zawodnik może uzyskać podobne wartości kilku wskaźników, ale ich zgodność nie jest zagwarantowana na poziomie indywidualnym. FTP ma przede wszystkim wartość funkcjonalną: umożliwia planowanie treningu na podstawie mocy rejestrowanej na rowerze. CP wynika z dopasowania modelu do kilku wysiłków, a progi fizjologiczne wymagają obserwacji reakcji organizmu w określonym protokole. Posługiwanie się tymi terminami zamiennie prowadziłoby do nadmiernego uproszczenia i mogłoby sugerować precyzję, której pojedynczy pomiar nie zapewnia.

Heurystyczny charakter przelicznika jest istotny również dla dalszej części pracy. Jeżeli etykieta modelu zostaje utworzona z maksymalnej średniej mocy 20-minutowej, model uczy się przybliżać właśnie tak zdefiniowaną wartość referencyjną. Nie oznacza to automatycznie, że estymuje bezpośrednio MLSS, CP albo wynik pełnego testu godzinnego. Rozróżnienie pomiędzy etykietą operacyjną a konstruktem fizjologicznym pozwala ostrożnie interpretować jakość predykcji.

1.2. Pomiar mocy w kolarstwie

Upowszechnienie mierników mocy stanowi jeden z kluczowych czynników umożliwiających rozwój ilościowej analizy treningu kolarskiego. W przeciwieństwie do prędkości, która jest silnie zależna od warunków zewnętrznych (takich jak siła i kierunek wiatru, nachylenie terenu czy opory toczenia), moc stanowi bezpośrednią i obiektywną miarę pracy mechanicznej wykonywanej przez zawodnika.

Pomiar mocy w kolarstwie opiera się zazwyczaj na rejestracji siły lub momentu obrotowego w wybranym elemencie układu napędowego roweru. Najpopularniejsze

rozwiązania techniczne umiejscawiają czujniki w pedałach, ramionach korby, pająku korby, osi suportu lub w piaście tylnego koła (Luder i in., 2024). Zasadniczym elementem pomiarowym w tego typu urządzeniach są tensometry. Te rezystancyjne czujniki rejestrują mikroskopijne odkształcenia elementów konstrukcyjnych pod wpływem nacisku stóp kolarza, co pozwala wyznaczyć siłę reakcji i moment obrotowy (Bouillod i in., 2022). Poprzez połączenie tych wartości z kadencją (częstotliwością obrotów korby) wyznacza się chwilową moc mechaniczną wyrażoną w watach.

Warto podkreślić, że miejsce instalacji czujnika wpływa na charakterystykę uzyskiwanych pomiarów. Mierniki zlokalizowane w pedałach lub ramionach korby mierzą moc bardzo blisko punktu przyłożenia siły, co minimalizuje wpływ strat mechanicznych w układzie napędowym (np. strat na łańcuchu czy łożyskach). Pozwala to również na niezależny pomiar mocy dla lewej i prawej nogi (tzw. pomiar obustronny), co umożliwia analizę asymetrii i techniki pedałowania. Z kolei mierniki umieszczone w piaście rejestrują użyteczną moc napędową przekazywaną bezpośrednio na koło, jednak ich wskazania są z natury pomniejszone o straty napędu.

Rozwój technologii produkcji, miniaturyzacja układów scalonych oraz popularyzacja energooszczędnych protokołów transmisji bezprzewodowej (takich jak ANT+ czy Bluetooth Low Energy) spowodowały, że urządzenia te stały się znacznie tańsze, bardziej niezawodne i szerzej dostępne dla amatorów. Wczesne systemy pomiarowe były zarezerwowane głównie dla profesjonalistów i laboratoriów badawczych z uwagi na zaporowe ceny i skomplikowaną obsługę. Współczesne mierniki cechują się dokładnością deklarowaną przez producentów w granicach 1 – 2% oraz posiadają wbudowane algorytmy aktywnej kompensacji wpływu temperatury w celu zapobiegania tzw. dryfowi zera (Bouillod i in., 2022).

Z punktu widzenia analizy danych i uczenia maszynowego kluczowy jest fakt, że mierniki mocy standardowo próbują i przesyłają dane z częstotliwością 1 Hz. Rejestrowany ciąg wartości tworzy gęsty szereg czasowy, który szczegółowo odwzorowuje strukturę wysiłku kolarza. Sygnał mocy charakteryzuje się jednak dużą zmiennością, występowaniem tzw. szumu, krótkotrwałymi pikami mocy oraz licznymi wartościami zerowymi wynikającymi z jazdy bez pedałowania (np. na zjazdach lub przed zakrętami). Ocena wiarygodności urządzenia powinna uwzględniać dokładność, czułość, powtarzalność, odtwarzalność i odporność na warunki pomiaru

(Bouillod i in., 2022). Dodatkowym źródłem błędu systematycznego mogą być mierniki jednostronne, które estymują moc całkowitą na podstawie pomiaru jednej kończyny i założenia symetrii pedałowania (Valenzuela i in., 2022). Popularyzacja mierników wygenerowała ogromną ilość rzeczywistych danych treningowych, które mogą być gromadzone w platformach sportowych i wykorzystywane w badaniach przekrojowych. Dostępność tych bogatych zbiorów ma bezpośrednie znaczenie dla badań wykorzystujących metody uczenia maszynowego do estymacji parametrów wydolnościowych, zapewniając odpowiednią wielkość próby do trenowania złożonych modeli predykcyjnych.

1.3. Znaczenie pomiaru mocy w treningu kolarskim

Współczesny trening kolarski coraz częściej opiera się na pomiarze mocy generowanej przez zawodnika. W przeciwieństwie do tętna czy subiektywnego odczucia wysiłku (RPE), moc jest parametrem bezpośrednio opisującym pracę mechaniczną wykonywaną na rowerze. Informuje wprost, ile energii w jednostce czasu kolarz przekazuje na napędzanie roweru, niezależnie od takich czynników jak stres, temperatura otoczenia czy chwilowe wahania nastroju (Allen i in., 2019; Phases Cycling, 2023).

Pomiar mocy ma kilka kluczowych zalet z punktu widzenia planowania i analizy treningu:

- **Obiektywność i powtarzalność** - ta sama wartość mocy oznacza ten sam poziom obciążenia zewnętrznego, niezależnie od dnia i samopoczucia zawodnika. Ułatwia to porównywanie wysiłków w czasie oraz między różnymi jednostkami treningowymi.
- **Dokładne sterowanie intensywnością** - strefy treningowe oparte na procentach FTP pozwalają precyzyjnie dozować obciążenie (np. trening progowy, $VO_{2\max}$, jazdy regeneracyjne), co sprzyja świadomemu kształtowaniu określonych adaptacji fizjologicznych (Allen i in., 2019).
- **Lepsza analiza obciążeń niż na podstawie tętna** - tętno reaguje z opóźnieniem i podlega wpływowi temperatury, odwodnienia czy stresu. Moc zmienia się natychmiast po zmianie nacisku na pedały, dzięki czemu lepiej odzwierciedla

przebieg wysiłku.

- **Możliwość zaawansowanej analizy danych** - rejestracja mocy w czasie pozwala obliczać wskaźniki (np. moc znormalizowana NP, TSS, czas spędzony w strefach), a także stosować modele matematyczne i metody uczenia maszynowego (Stockwell i Corradini, 2023; Denham i in., 2020).
- **Monitorowanie postępu i zmęczenia** - analiza danych z codziennych treningów umożliwia szacowanie zmian FTP i ogólnego poziomu wytrenowania bez konieczności częstego wykonywania formalnych testów laboratoryjnych (Borszcz i in., 2018; Karsten i in., 2021; Denham i in., 2020).

Z tych powodów moc stała się jednym z podstawowych parametrów używanych w treningu kolarskim na każdym poziomie zaawansowania - od amatorów po zawodowców. W kontekście niniejszej pracy jest to szczególnie istotne, ponieważ FTP pełni rolę kluczowego wskaźnika wydolności opartego właśnie na danych z pomiaru mocy.

1.4. Znaczenie FTP w praktyce treningowej

FTP jest szeroko stosowane zarówno w badaniach naukowych, jak i w codziennej praktyce trenerów i kolarzy (Borszcz i in., 2018; Allen i in., 2019; Karsten i in., 2021; Denham i in., 2020). Wartość tego parametru służy przede wszystkim do:

- wyznaczania stref treningowych - zakresy mocy (lub tętna) definiuje się jako procent FTP, co pozwala opisywać intensywność treningu w sposób bardziej obiektywny niż wyłącznie na podstawie odczuć;
- monitorowania postępów - wzrost FTP (np. z 250 W do 270 W) w pewnym okresie czasu interpretuje się jako poprawę wydolności tlenowej;
- porównywania zawodników - przeliczenie FTP na wartość względną $W\ kg^{-1}$ pozwala porównywać kolarzy o różnej masie ciała;
- planowania strategii wyścigowych - znajomość FTP pomaga oszacować tempo możliwe do utrzymania na długich podjazdach czy w jeździe indywidualnej na czas.

Z punktu widzenia uczenia maszynowego FTP jest naturalnym kandydatem na

zmienną wyjściową (etykietę, y) w modelach regresyjnych. Oznacza to, że model ma za zadanie przybliżyć zależność pomiędzy zarejestrowanymi danymi z treningów (moc, tętno, czas, parametry trasy) a „ukrytą” wartością FTP danego zawodnika (Stockwell i Corradini, 2023; Denham i in., 2020).


1.5. Podstawy fizjologii wysiłku istotne dla interpretacji FTP

Aby poprawnie interpretować dane używane przez model oraz ograniczenia tradycyjnych testów FTP, wystarczy uproszczony obraz fizjologii wysiłku:

- **Układ krążenia i tlen.** W trakcie wysiłku mięśnie potrzebują tlenu do wytwarzania energii. Serce pompuje krew bogatą w tlen, a tętno rośnie wraz z intensywnością wysiłku. W średnich intensywnościach wzrost mocy często wiąże się z niemal liniowym wzrostem tętna.
- **Progi metaboliczne.** Przy coraz większej intensywności organizm w coraz większym stopniu korzysta z procesów beztlenowych, a we krwi kumuluje się mleczan. W okolicach progów mleczanowych lub wentylacyjnych równowaga pomiędzy produkcją a usuwaniem mleczanu jest na granicy: organizm jest jeszcze w stanie utrzymać wysiłek, ale przy dalszym zwiększaniu obciążenia równowaga się załamuje i dochodzi do szybkiego narastania zmęczenia. FTP jest zwykle zlokalizowane w pobliżu tych progów, ale nie jest z nimi tożsame (Borszcz i in., 2018; Karsten i in., 2021; Denham i in., 2020).
- **Dryf tętna.** Podczas dłuższych wysiłków przy stałej mocy często obserwuje się zjawisko stopniowego wzrostu tętna w czasie, mimo że moc nie rośnie. Wynika to m.in. z narastającego zmęczenia, zmian w termoregulacji i niewielkiego spadku objętości krwi krążącej. Oznacza to, że relacja „moc–tętno” nie jest idealnie stała: ta sama moc po 5 minutach i po 40 minutach może odpowiadać innemu tętnu. Ponadto tętno reaguje na zmiany mocy z pewnym opóźnieniem, więc po nagłym zwiększeniu lub zmniejszeniu obciążenia serce potrzebuje zwykle kilkudziesięciu sekund, aby „dogonić” nowy poziom wysiłku. Z punktu widzenia modeli uczonych na danych sekunda-po-sekundzie oznacza to, że bieżąca wartość tętna odzwierciedla raczej średnie obciążenie z ostatnich kilkudziesięciu sekund niż chwilowy odczyt mocy.

- **Zmęczenie i wyczerpanie.** Gdy intensywność przekracza zdolność organizmu do stabilnego utrzymania równowagi metabolicznej, narastające zmęczenie prowadzi do konieczności zmniejszenia mocy. W testach FTP objawia się to przerwaniem wysiłku lub znaczącym obniżeniem mocy, co widać jako spadek mocy na wykresie (Borszcz i in., 2018; Karsten i in., 2021).

Zjawisko dryfu tętna przy stałej mocy oraz opóźnienie reakcji tętna po zmianie intensywności przedstawiono na rysunku 1.1.



Rysunek 1.1: Dryf tętna przy stałej mocy

Źródło: Opracowanie własne na podstawie (Nomad Frontiers, 2026; BikeRadar, 2023).

Wykres ten pełni funkcję poglądową: ilustruje fizjologiczne ograniczenia jednoczesnego stosowania tętna i mocy jako bezpośrednich wskaźników intensywności bez uwzględnienia czynnika czasu. Pokazuje, że relacja ta zmienia się dynamicznie w trakcie wysiłku, co wpływa na trudność modelowania tej zależności za pomocą prostych modeli regresyjnych. Z perspektywy modelu uczenia maszynowego oznacza to, że:

- sygnał tętna zawiera informację o reakcji organizmu na obciążenie (moc),
- relacja moc–tętno jest nieliniowa i zmienia się w czasie (dryf, narastające zmęczenie),
- pojedynczy test FTP jest jedynie pojedynczym pomiarem tej relacji w konkretnych warunkach oraz w konkretnym dniu.

Dlatego sensowne jest podejście, w którym model uczy się tej relacji z wielu treningów, zamiast polegać wyłącznie na jednym teście (Stockwell i Corradini, 2023; Denham i in., 2020).

Interpretacja wskaźników fizjologicznych wymaga także rozróżnienia ich funkcji. Pułap tlenowy VO_{2max} opisuje maksymalną zdolność organizmu do poboru i wykorzystania tlenu, ale sam nie określa mocy możliwej do długotrwałego utrzymania. Progi VT_1 i VT_2 identyfikuje się na podstawie zmian wentylacji oraz wymiany gazowej, natomiast LT_1 i LT_2 na podstawie przebiegu stężenia mleczanu. FTP jest związane z tym samym ogólnym obszarem wydolności, lecz stanowi wskaźnik terenowy i treningowy. Z tego powodu estymacja FTP z telemetrii jest użyteczna praktycznie, ale nie zastępuje pełnej diagnostyki laboratoryjnej.


1.6. Test 20-minutowy – przebieg i ilustracja

Najpopularniejszy protokół używany w praktyce do wyznaczania FTP to test 20-minutowy (Allen i in., 2019; Sitko i in., 2023; Phases Cycling, 2023). W praktyce treningowej standardowy protokół testowy, zaproponowany m.in. przez Allena i Coggana (Allen i in., 2019), składa się z kilku następujących po sobie faz o ściśle określonym celu fizjologicznym:

- **Faza wprowadzenia (rozgrzewka)** – obejmuje 10–20 minut jazdy o niskiej i umiarkowanej intensywności w celu pobudzenia układu krążeniowo-oddechowego.
- **Faza adaptacji (wysiłek przygotowawczy)** – polega na wykonaniu krótkiego (zwykle 3–5 minut) wysiłku o intensywności przewyższającej próg w celu wyczerpania komponentu beztlenowego przed próbą główną.
- **Faza regeneracji bezpośredniej** – kilkunastominutowy etap spokojnej jazdy ułatwiający utylizację mleczanu przed rozpoczęciem testu.
- **Próba zasadnicza** – 20-minutowy wysiłek maksymalny o stałej intensywności, podczas którego rejestrowana jest średnia moc stanowiąca bazę do wyznaczenia FTP.

Schemat przebiegu testu 20-minutowego zaprezentowano na rysunku 1.2. Schemat obejmuje rozgrzewkę, krótki wysiłek pobudzający, fragment spokojnej jazdy,

właściwy test w postaci dwudziestu minut możliwie równego wysiłku oraz odpoczynek w formie rozjazdu.



Rysunek 1.2: Schemat przebiegu testu 20-minutowego FTP

Źródło: Opracowanie własne na podstawie (Allen i in., 2019).

Przedstawiony schemat graficznie porządkuje sekwencyjny i sformalizowany charakter testu terenowego. Pokazuje, dlaczego regularna realizacja tak złożonego protokołu bywa kłopotliwa dla kolarzy-amatorów, co uzasadnia poszukiwanie metod pasywnej estymacji. Zjawisko dryfu tętna ma znaczenie również przy interpretacji testów 20-minutowych. Nawet przy względnie stabilnej mocy w części zasadniczej testu tętno może stopniowo wzrastać, co oznacza, że odpowiedź fizjologiczna organizmu nie jest stała w czasie. Z tego powodu cechy opisujące relację mocy i tętna powinny uwzględniać nie tylko wartości średnie, lecz także zmiany tej relacji w trakcie wysiłku.

Wynik próby zależy również od strategii tempa. Zbyt intensywny początek może doprowadzić do spadku mocy w końcowej części testu, natomiast nadmiernie zachowawcza jazda utrudnia wykorzystanie pełnego potencjału zawodnika. Porównywalność kolejnych pomiarów wymaga zbliżonych warunków, podobnego poziomu zmęczenia i właściwego przygotowania. Dla osoby trenującej rekreacyjnie spełnienie tych warunków przy regularnym powtarzaniu próby bywa trudne. Jest to jedna z przyczyn, dla których pasywna estymacja oparta na historii aktywności może stanowić wartościowe uzupełnienie formalnych testów.

1.7. Test 60-minutowy – przebieg i ilustracja


Choć w praktyce trenerskiej najczęściej stosuje się skrócone protokoły (np. test 20-minutowy), pełny, 60-minutowy test czasowy uznawany jest za najbardziej bezpośrednią i klasyczną metodę wyznaczania FTP. W ujęciu historycznym FTP definiowano jako moc, którą zawodnik jest w stanie utrzymać przez pełną godzinę jazdy ciągłej. Wymaga to jednak bardzo wysokiej dyspozycji, odpowiedniego przygotowania mentalnego oraz sprzyjających warunków, dlatego test stosuje się głównie w środowisku laboratoryjnym lub u doświadczonych kolarzy (Allen i in., 2019; Sitko i in., 2023).

Klasyczna procedura wyznaczania FTP, oparta na pełnym wysiłku godzinnym, jest metodologicznie zbliżona do prób czasowych na dystansie godzinnym (Allen i in., 2019). Strukturę tego testu można scharakteryzować następująco:

- **Rozgrzewka i aktywacja** – trwająca 15–20 minut jazda przygotowawcza o niskiej i średniej intensywności.
- **Etap przejściowy** – 5–10 minut jazdy o minimalnej intensywności, służącej stabilizacji tętna przed główną próbą.
- **Próba zasadnicza** – 60-minutowa ciągła jazda o maksymalnej możliwej do utrzymania mocy, gdzie średnia wartość mocy jest bezpośrednio przyjmowana jako FTP.

Przebieg pełnego testu 60-minutowego przedstawiono na rysunku 1.3.

Schemat ten pełni funkcję porównawczą względem uproszczonej próby 20-minutowej. Obrazuje ekstremalne wymagania fizjologiczne i psychiczne związane z godzinną jazdą na czas, co tłumaczy rzadkie stosowanie tego protokołu w praktyce.




Rysunek 1.3: Schemat przebiegu testu 60-minutowego FTP

Źródło: Opracowanie własne na podstawie (Allen i in., 2019).

1.8. Krzywa mocy i zależność FTP od czasu trwania wysiłku

Schematyczną zależność maksymalnej możliwej do utrzymania mocy od czasu trwania wysiłku przedstawiono na rysunku 1.4. Dla bardzo krótkich czasów wartości mocy są wysokie i szybko maleją, natomiast przy dłuższych wysiłkach krzywa stopniowo przechodzi w obszar mocy progowych związanych z Critical Power (CP) i FTP (Pinot i Grappe, 2011; Borszcz i in., 2018; Allen i in., 2019; Karsten i in., 2021). Krzywa mocy pokazuje, że maksymalna możliwa do utrzymania moc maleje wraz z wydłużaniem czasu wysiłku, a przy długich czasach zbliża się do poziomu odpowiadającego mocy progowej.

Wykres ten pełni funkcję teoretyczną: ilustruje nieliniową zależność pomiędzy czasem trwania wysiłku a możliwą do utrzymania mocą. Pokazuje, że wraz z wydłużaniem czasu wysiłku maksymalna średnia moc maleje, a wartości dla dłuższych interwałów są wykorzystywane do praktycznej oceny progu wysiłkowego oraz profilu wydolnościowego zawodnika.



Rysunek 1.4: Przykładowa krzywa mocy

Źródło: Opracowanie własne na podstawie koncepcji mocy krytycznej.

W praktyce platformy treningowe i oprogramowanie analityczne wykorzystują takie krzywe do estymacji parametrów wydolnościowych, w tym FTP, na podstawie danych z wielu treningów bez konieczności wykonywania osobnego testu (Borszcz i in., 2018; Allen i in., 2019; Karsten i in., 2021; Denham i in., 2020).

1.9. Charakterystyka danych treningowych

Modele uczenia maszynowego wykorzystywane do estymacji FTP opierają się na danych rejestrowanych podczas jazdy na rowerze. Podstawowym źródłem informacji jest miernik mocy instalowany w korbie, piaście, pedale lub suporcie, który z wysoką częstotliwością (najczęściej 1 Hz) rejestruje chwilową moc generowaną przez kolarza. Równolegle rejestrowane jest tętno za pomocą opaski na klatkę piersiową lub optycznego czujnika na nadgarstku. W zależności od konfiguracji sprzętu oraz platformy treningowej możliwe jest także zapisywanie dodatkowych parametrów, takich jak kadencja, prędkość, położenie GPS, nachylenie trasy czy wysokość nad poziomem morza (Allen i in., 2019; Phases Cycling, 2023; Kaggle (redlineracer), 2020; Liversedge, 2020).

W kontekście uczenia maszynowego dane te mają postać szeregów czasowych: dla każdej sekundy otrzymujemy wektor obserwacji zawierający m.in. moc [W], tętno [bpm] oraz znacznik czasu. Dodatkowo dostępne są metadane opisujące daną sesję:

typ treningu (jazda spokojna, interwały, wyścig), użyty sprzęt, warunki pogodowe, a także informacja o zawodniku (masa ciała, kategoria wiekowa, poziom sportowy). Otwarte zbiory danych wykorzystywane w literaturze oraz w niniejszej pracy obejmują zarówno pomiary wykonywane w warunkach laboratoryjnych, jak i dane z rzeczywistych treningów terenowych zapisane w formatach GPX, FIT czy CSV (Kaggle (redlineracer), 2020; Liversedge, 2020; Stockwell i Corradini, 2023).

Kluczową relacją wykorzystywaną przez model jest zależność pomiędzy mocą a tętnem. Moc odzwierciedla rzeczywistą pracę mechaniczną wykonywaną przez kolarza, natomiast tętno jest miarą reakcji układu krążenia na obciążenie wysiłkiem. Zależność ta ma charakter nieliniowy i jest modulowana wieloma czynnikami, takimi jak temperatura, poziom odwodnienia, stan zmęczenia czy stosowane leki. Dodatkowo w trakcie dłuższych wysiłków obserwuje się zjawisko dryfu tętna: stopniowego wzrostu częstości skurczów serca pomimo utrzymywania z grubsza stałej mocy (Borszcz i in., 2018; Karsten i in., 2021). Zjawiska te sprawiają, że proste modele liniowe mogą okazać się niewystarczające, natomiast stanowią naturalne pole zastosowania metod uczenia maszynowego zdolnych do modelowania złożonych, nieliniowych zależności (Stockwell i Corradini, 2023; Denham i in., 2020).

Istotnym wyzwaniem jest jakość danych treningowych. W realnych warunkach jazdy rejestrowane szeregi zawierają liczne fragmenty, które nie są bezpośrednio związane z wydolnością tlenową: zjazdy przy niskiej mocy, postoje na skrzyżowaniach, zakłócenia wynikające z utraty sygnału GPS lub błędów odczytu czujników. Dodatkowo w otwartych zbiorach danych spotyka się brakujące wartości, niespójne nazewnictwo treningów oraz różne częstotliwości próbkowania. Zanim dane zostaną wykorzystane w modelu, konieczne jest przeprowadzenie operacji wstępnego przetwarzania (filtrowanie, ujednolicanie częstotliwości próbkowania, uzupełnianie lub usuwanie braków oraz segmentacja jazdy).

Poszczególne sygnały niosą odmienny rodzaj informacji i są obciążone innymi źródłami błędów. Moc reaguje szybko na zmianę nacisku na pedały, lecz zerowe wartości mogą oznaczać zarówno odpoczynek na zjeździe, jak i fragment jazdy bez pedałowania. Tętno opisuje odpowiedź organizmu, ale reaguje z opóźnieniem, a jego brak może wynikać z niezapięcia pasa lub przerwania transmisji. Kadencja pomaga odróżnić aktywne pedałowanie od toczenia roweru, lecz również zależy

od działania czujnika. Prędkość i wysokość ułatwiają interpretację profilu trasy, ale podlegają wpływowi warunków zewnętrznych oraz jakości sygnału GPS. Znacznik czasu jest potrzebny do obliczania długości okien i agregacji, a jednocześnie ujawnia nieregularności próbkowania.

Dane terenowe są zatem bardziej zróżnicowane niż zapis próby laboratoryjnej prowadzonej na ergometrze. W laboratorium można kontrolować obciążenie, czas trwania stopni wysiłku, temperaturę oraz moment poboru próbek. W rzeczywistej jeździe występują zmiany nachylenia, ruch drogowy, wiatr i decyzje taktyczne zawodnika. Ta zmienność nie jest wyłącznie wadą: reprezentuje warunki, w których narzędzie miałoby działać. Wymaga jednak filtracji i inżynierii cech, aby model nie interpretował artefaktów pomiarowych jako informacji o wydolności.

1.10. Klasyczne podejścia a uczenie maszynowe w szacowaniu FTP

Tradycyjnie do wyznaczania FTP stosuje się metody oparte na prostych zależnościach matematycznych i z góry ustalonych protokołach testowych. Przykładem jest 20-minutowy test czasowy, w którym FTP definiuje się jako stały procent średniej mocy z próby (Allen i in., 2019; Sitko i in., 2023; Phases Cycling, 2023). Inne podejścia bazują na modelu mocy–czasu (CP), gdzie na podstawie kilku testów o różnym czasie trwania estymuje się parametry krzywej opisującej zależność pomiędzy czasem wysiłku a możliwą do utrzymania mocą (Denham i in., 2020). W diagnostyce sportowej wykorzystuje się również pułap tlenowy (VO_{2max}), progi wentylacyjne (VT_1 , VT_2) oraz progi mleczanowe (LT_1 , LT_2). Wskaźniki te mają istotną wartość naukową i pozwalają precyzyjnie opisać reakcję organizmu na narastające obciążenie. Ich regularne wyznaczanie wymaga jednak laboratorium, specjalistycznej aparatury i obsługi, a w przypadku progów mleczanowych także pobierania próbek krwi. Testy są obciążające dla zawodnika, kosztowne i trudne do częstego powtarzania, szczególnie w sporcie amatorskim (Borszcz i in., 2018; Karsten i in., 2021).

Ocena laboratoryjna może obejmować analizator gazów oddechowych, ergometr umożliwiający kontrolę obciążenia, pomiar tętna oraz procedurę pobierania próbek krwi. Przeprowadzenie badania wymaga odpowiedniego przygotowania zawodnika i personelu, a wynik odnosi się do konkretnego dnia oraz przyjętego protokołu. Powtarzanie pełnej diagnostyki w krótkich odstępach czasu jest zwykle

nieproporcjonalne do potrzeb amatora. Nawet w sporcie wyczynowym badania laboratoryjne planuje się w wybranych momentach cyklu treningowego, a bieżące monitorowanie opiera również na danych z treningów.

Zaletą klasycznych metod jest prostota interpretacji oraz możliwość odniesienia wyniku do mechanizmów fizjologicznych. Jednocześnie podejścia te zakładają wykonanie jednego lub kilku wysiłków w kontrolowanych warunkach, a uzyskana wartość ma charakter punktowy: opisuje stan zawodnika w chwili testu. Zmiany wydolności pomiędzy testami pozostają niewidoczne, co ogranicza możliwość ciągłego monitorowania formy (Denham i in., 2020; Phases Cycling, 2023). Ograniczenia te uzasadniają wykorzystanie danych telemetrycznych rejestrowanych w codziennych treningach oraz modeli uczenia maszynowego, które mogą agregować informacje z wielu sesji.

Rozwój uczenia maszynowego oraz dostęp do dużych zbiorów danych treningowych otwierają alternatywną ścieżkę: zamiast opierać się wyłącznie na dedykowanych testach, można wykorzystać informacje zawarte w codziennych jazdach. W literaturze pojawiają się projekty open-source, w których na podstawie historii treningów buduje się modele regresyjne przewidujące wartość FTP wyznaczoną testem referencyjnym (Stockwell i Corradini, 2023; Denham i in., 2020). Rozwiązania te stanowią naturalny punkt odniesienia dla niniejszej pracy i pokazują, że podejście oparte na danych ma potencjał praktycznego zastosowania.

Typowo stosowane modele można podzielić na dwie główne grupy:

- **Modele oparte na cechach zagregowanych.** Z surowych szeregów czasowych wyznacza się zestaw cech opisujących jazdę lub jej fragment (np. średnia moc i tętno, maksymalna moc z 5- czy 20-minutowego okresu, czas w strefach, miary zmienności). Na tak przygotowanych danych uczą algorytmy regresji, takie jak regresja liniowa, Random Forest czy modele Gradient Boosting (np. XGBoost). Zaletą jest interpretowalność i relatywnie niewielkie wymagania obliczeniowe (Stockwell i Corradini, 2023).
- **Modele sekwencyjne.** Podejście polega na bezpośrednim modelowaniu szeregów czasowych (bez redukcji do kilku wskaźników). Wykorzystuje się architektury neuronowe takie jak LSTM, GRU czy modele typu *Transformer* przystosowane do danych czasowych. Umożliwia to uchwycenie złożonych

wzorców dynamiki wysiłku, jednak wymaga większej ilości danych, starannego doboru hiperparametrów i jest trudniejsze do interpretacji (Stockwell i Corradini, 2023).

Oba podejścia nie wykluczają się wzajemnie. W praktyce często tworzy się hybrydowe pipeline'y, w których część informacji pochodzi z cech zagregowanych, a część z modeli sekwencyjnych. W niniejszej pracy przyjęto podejście regresyjne, w którym FTP traktowane jest jako zmienna ciągła, a celem jest minimalizacja błędu predykcji względem wartości referencyjnych wyznaczonych testami.

Wybór algorytmu do estymacji parametrów fizjologicznych jest kluczowy dla skuteczności modelu. W literaturze przedmiotu najczęściej wymienia się następujące podejścia (Stockwell i Corradini, 2023):

Pierwszą grupę rozważanych podejść stanowią modele liniowe i metody regularyzacji. Podstawowym narzędziem w zadaniach predykcji wartości ciągłej, takiej jak FTP, jest regresja liniowa. Zakłada ona liniową zależność między cechami wejściowymi (np. średnim tętnem, mocą z określonych przedziałów czasowych) a zmienną celu. Choć fizjologia wysiłku ma charakter nieliniowy, modele liniowe stanowią dobry punkt odniesienia. Aby zapobiec przeuczeniu przy dużej liczbie skorelowanych cech, stosuje się regularyzację:

- **Lasso** (ℓ_1) - umożliwia selekcję cech poprzez zerowanie współczynników przy mniej istotnych zmiennych,
- **Ridge** (ℓ_2) - zmniejsza wariancję modelu, co jest korzystne przy współliniowości danych treningowych.

Drugą grupę stanowią metody zespołowe, należące do najskuteczniejszych algorytmów stosowanych w pracy z danymi tabelarycznymi. W podejściu tym wykorzystuje się modele oparte na drzewach decyzyjnych. Pojedyncze drzewo ma tendencję do nadmiernego dopasowania, dlatego stosuje się:

- **Random Forest**, czyli metoda lasu losowego - wykorzystuje agregację bootstrapową, buduje wiele drzew decyzyjnych na losowych podzbiorach danych i cech, a następnie uśrednia predykcje. Dzięki temu jest odporniejsza na przeuczenie niż pojedyncze drzewo i dobrze sprawdza się w danych tabelarycznych zawierających zależności nieliniowe.

- **Gradient Boosting** - buduje drzewa sekwencyjnie, a kolejne drzewa korygują błędy predykcji popełnione przez wcześniejsze elementy modelu. XGBoost jest wydajną implementacją tego podejścia, rozwiniętą z myślą o skutecznym uczeniu na danych tabelarycznych.

W części empirycznej pracy modele Random Forest i XGBoost wykorzystano do regresyjnej estymacji FTP, natomiast Ridge Regression pełni rolę liniowego punktu odniesienia.

Niezależnie od wybranej klasy modelu istotnym zagrożeniem pozostaje wyciek danych. W zadaniach predykcyjnych należy oddzielić informację dostępną w rzeczywistym zastosowaniu od informacji, która powstała bezpośrednio podczas tworzenia etykiety. Data leakage występuje wtedy, gdy predyktor przekazuje modelowi część odpowiedzi lub pozwala ją odtworzyć w sposób niedostępny w docelowym scenariuszu. Skutkiem może być bardzo wysoka wartość R^2 i niski błąd, które nie świadczą o generalizacji modelu (Kaufman i in., 2012; Bernett i in., 2024).

W przypadku heurystycznego FTP ryzyko jest szczególnie wyraźne. Jeżeli wartość referencyjną obliczono jako 0,95 maksymalnej średniej mocy 20-minutowej, pozostawienie cechy `mmp_20min` w zbiorze wejściowym umożliwia niemal bezpośrednio odtworzenie etykiety. Kontrola listy cech jest zatem równie ważna jak wybór algorytmu i metryk. Sama wysoka jakość dopasowania nie wystarcza do uznania eksperymentu za wiarygodny, jeżeli nie zbadano pochodzenia predyktorów oraz sposobu podziału danych.

Alternatywę dla modeli uczonych na cechach zagregowanych stanowią sieci neuronowe i metody głębokiego uczenia. Gdy dane wejściowe są traktowane jako surowy szereg czasowy, czyli sekwencja próbek mocy i tętna rejestrowanych co 1 sekundę, intensywna inżynieria cech może prowadzić do utraty informacji o dynamice zmian. W takich przypadkach zastosowanie znajdują:

- rekurencyjne sieci neuronowe (RNN) oraz LSTM,
- konwolucyjne sieci neuronowe 1D (1D-CNN),
- modele typu *Transformer* dla szeregów czasowych.

1.11. Zarys procesu przetwarzania danych i budowy modelu

Zastosowanie uczenia maszynowego do estymacji FTP wymaga zdefiniowania spójnego procesu przetwarzania danych obejmującego następujące etapy.

Pierwszym etapem procesu było pozyskanie i zintegrowanie danych. W pracy wykorzystano otwarte zbiory danych zawierające zarówno wyniki testów wydolnościowych, jak i towarzyszące im szeregi czasowe mocy oraz tętna (Kaggle (redlineracer), 2020; Liversedge, 2020; Stockwell i Corradini, 2023). Uzupełnieniem są pliki GPX/FIT z regularnych jazd terenowych, przetworzone w ramach potoku ETL opisanego w rozdziale drugim.

Następnie dane zostały przygotowane do dalszej analizy. Etap ten (ang. *preprocessing*) obejmował m.in. filtrację artefaktów pomiarowych, ujednolicenie częstotliwości próbkowania oraz obsługę brakujących wartości. Jakość tego etapu ma bezpośredni wpływ na stabilność cech i modeli.

Kolejnym krokiem było zdefiniowanie etykiety predykcyjnej. Naturalnym wyborem jest FTP wyznaczone na podstawie standaryzowanego testu referencyjnego (np. testu 20-minutowego skorygowanego współczynnikiem) lub wyniku laboratoryjnego odpowiadającego mocy progowej (Borszcz i in., 2018; Karsten i in., 2021; Denham i in., 2020). Następnie dla treningów wykonywanych w określonym oknie czasowym względem testu (np. ± 2 tygodnie) przyjmuje się tę samą wartość FTP, co pozwala przypisać etykietę do wielu sesji bez wykonywania dodatkowych testów (Stockwell i Corradini, 2023; Denham i in., 2020). Jest to świadome założenie modelowe: w krótkim horyzoncie czasu FTP zmienia się relatywnie wolno.

Po zdefiniowaniu etykiety przeprowadzono inżynierię cech (ang. *feature engineering*). Polegała ona na wyznaczeniu z surowych danych cech opisujących wysiłek i reakcję organizmu: średnich i maksymalnych mocy w oknach czasowych, rozkładu czasu w strefach, relacji mocy do tętna, miar zmienności tętna oraz wskaźników dryfu tętna.

Ostatni etap obejmował trening i ewaluację modeli. W zależności od projektu badania zbiór danych może zostać podzielony z uwzględnieniem grupowania obserwacji na poziomie zawodnika lub bloku czasowego. W finalnym eksperymencie opisanym w niniejszej pracy zastosowano pojedynczy podział treningowy i testowy

z użyciem mechanizmu `GroupShuffleSplit` grupującego obserwacje po zawodniku. Takie rozwiązanie ogranicza ryzyko wystąpienia data leakage pomiędzy sesjami tej samej osoby (Tougui i in., 2021; Rosenblatt i in., 2024). Jako miary jakości predykcji stosuje się typowo MAE, RMSE oraz miary korelacji i determinacji, w tym R^2 (Chai i Draxler, 2014; James i in., 2021; Hastie i in., 2009).

Obiektywna ocena jakości estymacji FTP wymaga zdefiniowania miar błędu modelu. W problemach regresji standardowo stosuje się m.in. następujące metryki (James i in., 2021; Hastie i in., 2009).

Metryki te obejmują:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (1.2)$$

gdzie y_i oznacza rzeczywistą wartość FTP (wyznaczoną na podstawie testu referencyjnego), a $\hat{y}_i$ odpowiadającą jej wartość przewidywaną przez model. RMSE jest wrażliwy na duże błędy (obserwacje odstające), co jest pożądane w zastosowaniach sportowych, ponieważ duże pomyłki mogłyby prowadzić do niewłaściwego doboru obciążeń treningowych.

Średni błąd bezwzględny (MAE).

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (1.3)$$

MAE jest łatwiejsze w interpretacji dla trenera, ponieważ wprost mówi, o ile watów średnio myli się model (np. „średni błąd wynosi 5 W”).

Współczynnik determinacji (R^2).

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (1.4)$$

gdzie $\bar{y}$ oznacza średnią wartość rzeczywistego FTP w próbie. Wartość bliska $R^2 = 1$ oznacza bardzo dobre dopasowanie modelu do danych, natomiast wartości ujemne świadczą o tym, że model przewiduje gorzej niż proste przyjęcie średniej z próby. W badaniach nad wydolnością wysokie wartości R^2 (np. powyżej 0,9) pomiędzy wynikami testów skróconych a pełnymi bywają interpretowane jako przesłanka użyteczności danej metody estymacji (Karsten i in., 2021).

1.12. Przegląd badań naukowych i istniejących rozwiązań

1.12.1. Badania nad FTP i mocą krytyczną

Rozwój nauk o sporcie na przełomie XX i XXI wieku wiązał się z dążeniem do ilościowego opisu wydolności fizycznej. W dyscyplinach wytrzymałościowych istotnym zagadnieniem stała się identyfikacja progów metabolicznych, które wyznaczają granicę pomiędzy wysiłkiem możliwym do dłuższego utrzymania a intensywnością prowadzącą do szybkiego narastania zmęczenia.

W praktyce treningowej znaczącą rolę odegrała koncepcja Functional Threshold Power opisana przez Allena i Coggana (Allen i in., 2019). FTP stanowi praktyczny wskaźnik funkcjonalny powiązany z wysiłkiem możliwym do utrzymania przez około godzinę. Nie jest jednak bezpośrednim odpowiednikiem pojedynczego progu fizjologicznego. Borszcz i współpracownicy (Borszcz i in., 2018) wykazali, że pomiędzy FTP a parametrami laboratoryjnymi mogą występować indywidualne różnice w odpowiedzi fizjologicznej. Jednocześnie w innym badaniu (Borszcz i in., 2019) zaobserwowano silną korelację FTP z MLSS, choć ze znaczną indywidualną zmiennością, co stawia pod znakiem zapytania ich pełną zamiennność. Oznacza to, że FTP jest użytecznym wskaźnikiem treningowym, lecz jego interpretacja wymaga ostrożności.

Blisko spokrewnioną koncepcją jest Critical Power (CP). W klasycznym modelu Monoda i Scherrera zależność pomiędzy wykonaną pracą a czasem wysiłku opisuje równanie:

$$W = CP \cdot t + W', \quad (1.5)$$

gdzie W oznacza całkowitą wykonaną pracę, CP jest mocą krytyczną, t oznacza czas trwania wysiłku, natomiast W' reprezentuje skończony zasób pracy możliwej do wykonania powyżej progu CP . Z równania wynika, że przy dłuższych wysiłkach znaczenie zasobu W' maleje, a średnia moc zbliża się do poziomu CP .

Karsten i współpracownicy (Karsten i in., 2021) oraz McGrath i współpracownicy (McGrath i in., 2021) analizowali relację pomiędzy FTP a CP . Wyniki tych prac wskazują, że oba parametry są pojęciowo bliskie, lecz nie są w pełni tożsame. Z kolei Sitko i współpracownicy (Sitko i in., 2023) zwrócili uwagę na zmienność relacji pomiędzy mocą z testu 20-minutowego a wynikiem próby 60-minutowej. Ogranicza to możliwość

bezwartunkowego stosowania jednego przelicznika dla wszystkich zawodników.

Z perspektywy niniejszej pracy wniosek ten ma podwójne znaczenie. Po pierwsze, uzasadnia ostrożne traktowanie etykiety FTP obliczonej z próby 20-minutowej. Jest ona przydatna do przygotowania dużego zbioru historycznego, ponieważ można ją wyznaczyć automatycznie dla wielu sesji, ale pozostaje przybliżeniem. Po drugie, wskazuje, że model nie powinien być oceniany wyłącznie przez zdolność do odtworzenia przelicznika 0,95. Ważniejsze jest sprawdzenie, czy po usunięciu bezpośredniego predyktora nadal wykorzystuje szerszy kontekst treningu.

Badania nad czasem utrzymania wysiłku na poziomie estymowanego FTP również pokazują, że funkcjonalna interpretacja progu wymaga uwzględnienia różnic międzyosobniczych (Sitko i in., 2022). U dwóch zawodników ta sama procedura może prowadzić do wartości o odmiennym znaczeniu praktycznym, jeżeli różnią się profilem wytrzymałości i tolerancją wysiłku. Nie podważa to użyteczności FTP w planowaniu treningu, lecz przemawia za prezentowaniem estymacji jako wskaźnika obciążonego niepewnością.

Warto również odróżnić cel pomiaru laboratoryjnego od celu pasywnego monitorowania. Diagnostyka laboratoryjna umożliwia szczegółowy opis reakcji fizjologicznej przy kontrolowanym obciążeniu. Rozwiązanie analityczne oparte na telemetrii ma inny charakter: wykorzystuje dane dostępne częściej, ale mniej jednolite. Jego przewagą nie jest zastąpienie laboratorium większą precyzją, lecz dostarczanie dodatkowej informacji pomiędzy formalnymi testami.

1.12.2. Uczenie maszynowe w analizie telemetrii sportowej

Metody uczenia maszynowego umożliwiają odejście od analizy pojedynczego testu na rzecz wykorzystania historii treningów. Modele mogą uwzględniać jednocześnie statystyki mocy, tętna, kadencji, czasu trwania wysiłku oraz rozkładu intensywności, a następnie szacować FTP jako zmienną ciągłą.

Stockwell i Corradini (Stockwell i Corradini, 2023) zaproponowali wieloetapowy potok estymacji FTP oparty na danych kolarskich. Porównanie modeli liniowych oraz algorytmów drzewiastych wskazało przydatność metod zdolnych do odwzorowania zależności nieliniowych. Karetnikov i współpracownicy (Karetnikov i in., 2021) zastosowali zagregowane dane treningowe i wyścigowe do predykcji profilu MMP zawodowych kolarzy. Denham i współpracownicy (Denham i in., 2020) analizowali

możliwość przewidywania parametrów wydolnościowych na podstawie krótszych prób wysiłkowych. Przegląd systematyczny Stessens i in. (2024) wskazuje, że modele terenowe i technologie ubieralne mogą ułatwiać regularne monitorowanie, ale nie zastępują diagnostyki laboratoryjnej. Użyteczność algorytmów ML w estymacji kluczowych progów fizjologicznych została szerzej zbadana na przykładzie m.in. pułapu tlenowego (VO_2max), dla którego modele, szczególnie sztuczne sieci neuronowe, wykazują dużą skuteczność predykcyjną (Ashfaq i in., 2022). Wyniki tych badań uzasadniają stosowanie modeli regresyjnych, ale również pokazują, że nietypowy profil fizjologiczny zawodnika może ograniczać trafność prostych zależności liniowych.

Literatura metodologiczna dotycząca zastosowań ML w sporcie podkreśla, że jakość modelu zależy nie tylko od wyboru algorytmu, lecz także od konstrukcji zbioru danych, separacji próby testowej i interpretacji ograniczeń wdrożeniowych. W szczególności dane tego samego zawodnika nie powinny jednocześnie trafiać do zbioru treningowego i testowego, ponieważ prowadziłoby to do zawyżenia oceny generalizacji (Richter i in., 2021; Rossi i in., 2022; Fuller i in., 2022).

Istotnym zagrożeniem metodologicznym jest data leakage, czyli sytuacja, w której model korzysta z informacji niedostępnej w realistycznym scenariuszu predykcji. Jeżeli etykieta FTP została obliczona na podstawie 20-minutowej mocy maksymalnej, wykorzystanie cechy `mmp_20min` jako predyktora prowadzi do odtworzenia zależności arytmetycznej zamiast rzeczywistej estymacji na podstawie telemetrii (Kaufman i in., 2012; Bernett i in., 2024; Dong, 2022). Z tego względu w części empirycznej wariant A pełni wyłącznie funkcję kontrolną, wariant B jest głównym wariantem badawczym, a wariant C stanowi wariant konserwatywny.

Z punktu widzenia projektu rozwiązania istotne jest przejście od pojedynczego sygnału do zestawu cech opisujących różne aspekty aktywności. Moc maksymalna w wybranym oknie czasowym informuje o zdolności do wykonania intensywnego wysiłku, ale nie opisuje całego treningu. Statystyki tętna, czas aktywnego pedałowania, rozkład intensywności oraz miary odsprężenia uzupełniają obraz o reakcję organizmu i charakter jednostki. Modele drzewiaste są użyteczne w takim zadaniu, ponieważ mogą odwzorowywać zależności nieliniowe oraz interakcje pomiędzy predyktorami, których prosta regresja liniowa nie ujmuje bez dodatkowej transformacji cech (Hastie i in., 2009;

James i in., 2021).

Drugim źródłem nadmiernie optymistycznej oceny może być nieprawidłowy podział obserwacji. W danych treningowych jedna osoba dostarcza zwykle wiele sesji, a jej aktywności mają powtarzalne cechy: typowy zakres mocy, charakterystyczną relację mocy do tętna i podobny sposób realizacji treningów. Jeżeli rekordy tego samego zawodnika znajdują się jednocześnie w części treningowej i testowej, model może korzystać z pośredniej identyfikacji osoby. Zjawisko to jest określane jako konfundowanie tożsamości (ang. *identity confounding*). Dlatego wiarygodna ocena wymaga testu na zawodnikach nieobecnych podczas uczenia (Saeb i in., 2017; Chaibub Neto i in., 2019; Tougui i in., 2021; Rosenblatt i in., 2024).

Znaczenie literatury dotyczącej uczenia maszynowego nie ogranicza się zatem do wskazania potencjalnie skutecznego algorytmu. Dla niniejszej pracy równie ważne są zasady konstrukcji eksperymentu: jawne pochodzenie etykiety, kontrola listy cech, osobniczy podział danych i interpretacja kilku metryk regresyjnych. Dopiero łączne zastosowanie tych elementów pozwala oddzielić jakość modelu od artefaktu przygotowania zbioru.

1.12.3. Istniejące systemy analityczne

Rozwiązania służące do analizy treningu kolarskiego można podzielić na platformy komercyjne oraz oprogramowanie otwarte. Platformy TrainingPeaks i WKO wykorzystują modele krzywej mocy w czasie do wyznaczania parametrów treningowych. Ekosystemy urządzeń sportowych, takie jak Garmin Connect i Wahoo SYSTM, oferują funkcje szacowania FTP na podstawie danych zarejestrowanych podczas aktywności.

W środowisku otwartego oprogramowania istotną rolę odgrywa GoldenCheetah. Program udostępnia narzędzia analizy telemetrii i modele wydolnościowe, a inicjatywa GoldenCheetah OpenData umożliwia prowadzenie badań na zanonimizowanych danych treningowych udostępnionych w ramach projektu Open Science Framework (OSF) (Liversedge, 2020). Dane z tego repozytorium wykorzystano w części empirycznej niniejszej pracy.

Systemy analityczne potwierdzają praktyczne zapotrzebowanie na automatyczną interpretację historii aktywności. Ich wyniki należy jednak czytać w kontekście zastosowanego modelu, dostępnych sygnałów oraz jakości rejestracji. Użytkownik

końcowy widzi zwykle pojedynczą wartość lub trend, podczas gdy za wynikiem stoją decyzje dotyczące filtracji, doboru okna czasowego i sposobu wyznaczenia wartości referencyjnej. W projekcie badawczym decyzje te powinny być opisane jawnie, aby możliwe było odtworzenie eksperymentu i ocena ograniczeń.

Otwarte repozytorium GoldenCheetah ma w tym kontekście szczególną wartość. Pozwala analizować sesje zarejestrowane poza laboratorium i sprawdzić zachowanie pipeline'u na zróżnicowanych historiach treningowych. Taki zbiór nie zapewnia pełnej kontroli jakości każdego czujnika ani jednolitego protokołu FTP, ale lepiej reprezentuje heterogeniczność danych spotykanych w zastosowaniu terenowym. Stanowi więc właściwy materiał do prototypowej oceny metody pasywnej, o ile wnioski pozostają proporcjonalne do jakości etykiet i zakresu walidacji.

1.12.4. Wykorzystane technologie i narzędzia

Implementację potoku przetwarzania danych oraz eksperymentów uczenia maszynowego zrealizowano w języku Python, który jest szeroko stosowany w analizie danych i uczeniu maszynowym ze względu na rozbudowany ekosystem bibliotek naukowych oraz czytelną składnię.

Do przetwarzania i transformacji danych tabelarycznych wykorzystano bibliotekę `pandas`, umożliwiającą wydajne operacje na ramkach danych, agregację, filtrację oraz łączenie zbiorów. Operacje numeryczne, w tym obliczenia na tablicach wielowymiarowych, realizowano za pomocą biblioteki `NumPy`.

Modele regresyjne Ridge Regression oraz Random Forest przygotowano z wykorzystaniem biblioteki `scikit-learn`, która dostarcza ujednolicony interfejs do treningu, predykcji i ewaluacji modeli, a także narzędzia do podziału danych (`GroupShuffleSplit`) i obliczania metryk jakości (Pedregosa i in., 2011). Model XGBoost zaimplementowano z użyciem dedykowanej biblioteki `xgboost`, stanowiącej wydajną implementację algorytmu Gradient Boosting.

Wizualizację wyników, w tym wykresy porównawcze metryk, wykresy predykcji względem wartości rzeczywistych, rozkłady reszt oraz rankingi ważności cech, przygotowano z użyciem biblioteki `matplotlib`.

Cały proces badawczy zorganizowano w postaci skryptowego potoku ETL (*Extract–Transform–Load*). Poszczególne etapy — od pobrania i rozpakowania archiwów, przez ekstrakcję cech, po trening modeli i generowanie raportów —

są realizowane przez osobne skrypty wywoływane sekwencyjnie. Takie podejście umożliwia selektywne powtórzenie wybranego etapu bez konieczności uruchamiania całego procesu od początku.

Powtarzalność eksperymentów zapewniono przez ustalenie ziarna generatora liczb losowych (`random_state=42`), jawne definiowanie ścieżek wejściowych i wyjściowych, wersjonowanie kodu źródłowego w systemie Git oraz archiwizację plików wynikowych. Dzięki temu możliwe jest odtworzenie wyników na podstawie udostępnionych skryptów i danych wejściowych.

1.13. Podsumowanie części teoretycznej

FTP jest praktycznym, ale uproszczonym wskaźnikiem wydolności kolarskiej. Tradycyjne testy i diagnostyka laboratoryjna dostarczają wartościowych informacji, lecz są obciążające i trudne do częstego wykonywania. Rejestrowana podczas codziennych treningów telemetria tworzy podstawę do pasywnego szacowania FTP z wykorzystaniem modeli regresyjnych. Warunkiem wiarygodnej oceny takich modeli jest rozdzielenie danych zawodników pomiędzy zbiory treningowy i testowy oraz kontrola cech mogących prowadzić do wycieku informacji.

Przegląd literatury wskazuje, że istotą problemu nie jest znalezienie jednego wzoru zastępującego każdy test, lecz połączenie kilku źródeł informacji w powtarzalnym procesie analitycznym. Moc, tętno, kadencja i charakter treningu opisują różne aspekty wysiłku. Ich wykorzystanie wymaga filtracji danych terenowych, przemyślanej inżynierii cech i ostrożnego doboru etykiety. W części empirycznej przyjęto właśnie takie podejście: wariant kontrolny ujawnia skutki data leakage, wariant główny ocenia predykcję bez bezpośredniej cechy etykietującej, a wariant konserwatywny sprawdza zachowanie modeli po usunięciu całej grupy cech MMP.

Rozdział 2. Metodologia badań i projekt rozwiązania

Rozdział opisuje sposób przejścia od problemu sformułowanego we wstępie do powtarzalnego eksperymentu. Przedstawiono w nim źródło danych, kolejne etapy ich przygotowania, definicję operacyjnej etykiety FTP, warianty cech oraz zasady podziału i oceny modeli.

Opracowane rozwiązanie ma charakter prototypowego systemu analitycznego. Jego zadaniem jest przekształcenie surowych danych telemetrycznych z treningów kolarskich w tabelaryczny zestaw cech, przygotowanie etykiet FTP oraz ocena modeli regresyjnych. System realizuje potok Extract–Transform–Load (ETL), obejmujący pozyskanie danych, ich filtrację, ekstrakcję cech oraz przygotowanie zbioru do eksperymentów uczenia maszynowego.

2.1. Architektura potoku przetwarzania


Przetwarzanie danych zaprojektowano jako sekwencję etapów, z których każdy ma określone wejście i wyjście. Rozdzielenie odpowiedzialności ułatwia kontrolę jakości, ponowne uruchamianie wybranego fragmentu procesu oraz identyfikację miejsca, w którym powstał ewentualny błąd. Ogólny przebieg potoku obejmuje:

1. pozyskanie archiwów ZIP zawierających historie treningowe użytkowników;
2. kontrolowane rozpakowanie kolejnych paczek danych;
3. identyfikację i odczyt plików .csv opisujących sesje;
4. przetworzenie szeregów czasowych oraz agregację cech na poziomie aktywności;
5. utworzenie heurystycznej etykiety `ftp_label`;
6. zastosowanie filtra wartości FTP i zapis tabelarycznego datasetu;
7. przygotowanie wariantów cech A, B i C;
8. trening modeli oraz ewaluację na osobniczo wydzielonym zbiorze testowym.

Taki układ oddziela etap danych surowych od etapu modelowania. Eksperymenty uczenia maszynowego nie operują bezpośrednio na plikach źródłowych, lecz na przygotowanym datasecie sesji. Dzięki temu porównanie wariantów cech i

modeli odbywa się na tej samej podstawie materiałowej, a ponowne uruchomienie eksperymentu nie wymaga każdorazowego przetwarzania wszystkich archiwów.

Całościowy przepływ danych od repozytorium źródłowego do interpretacji wyników przedstawiono na rysunku 2.1. Diagram porządkuje etapy przygotowania telemetrii, tworzenia wariantów eksperymentalnych, separacji zawodników oraz oceny modeli regresyjnych.



Rysunek 2.1: Schemat architektury potoku analitycznego

Źródło: Opracowanie własne.

Diagram ten pełni funkcję przewodnika po metodologii pracy: porządkuje kolejne kroki od surowej telemetrii do ewaluacji modeli. Pokazuje, że przygotowanie danych i separacja zawodników stanowią kluczowe etapy przed samym modelowaniem regresyjnym.

2.2. Charakterystyka źródeł danych

Podstawę materiałową badań stanowiły zanonimizowane dane treningowe ze zbioru GoldenCheetah OpenData udostępnionego w ramach projektu Open Science Framework (OSF) (Liversedge, 2020). Zastosowanie otwartego repozytorium pozwoliło objąć analizą zawodników o zróżnicowanym poziomie wytrenowania oraz sesje rejestrowane w warunkach terenowych.

Użytkownicy GoldenCheetah OpenData nie muszą być reprezentatywni dla całej populacji kolarzy: korzystają z określonego oprogramowania, rejestrują aktywności w określony sposób i zdecydowali się udostępnić dane w otwartym repozytorium. Ograniczenie to dotyczy możliwości uogólniania wyników na inne populacje, a nie użyteczności zbioru w ramach przeprowadzonego badania.

Wykorzystany zbiór GoldenCheetah OpenData ma charakter wtórny i obejmuje dane treningowe udostępnione w postaci zanonimizowanych archiwów aktywności. Analiza nie obejmowała danych osobowych zawodników ani prób ich identyfikacji, a identyfikatory sportowców traktowano wyłącznie jako techniczne grupy potrzebne do kontroli podziału danych i ograniczenia ryzyka przecieku informacji osobniczej.

Po kontrolowanym przetwarzaniu wykorzystano 781 archiwów ZIP zawierających dane użytkowników oprogramowania GoldenCheetah. Surowe dane wejściowe miały postać szeregów czasowych opisujących między innymi moc, tętno oraz kadencję. Skrypt ekstrakcji przekształcał pliki .csv zagnieżdżone w archiwach ZIP w tabelę, w której pojedynczy rekord odpowiada jednej sesji treningowej.

Pojedyncza aktywność sportowa nie jest reprezentowana przez jedną wartość, lecz przez sekwencję rekordów telemetrycznych rejestrowanych w czasie (np. co sekundę). Każdy rekord może zawierać pomiary takie jak moc, tętno, kadencja, prędkość, wysokość czy dystans. W plikach aktywności mogą występować również informacje lokalizacyjne, jednak w niniejszej pracy nie były one wykorzystywane ze względu na anonimizację. Przykładowy zanonimizowany fragment zapisu telemetrycznego przedstawiono w tabeli 2.1.

Tabela 2.1 prezentuje jedynie 10 początkowych rekordów jednej aktywności, która w całości może obejmować od kilku do kilkunastu tysięcy pomiarów. Z takich sekwencji obliczane są następnie cechy zagregowane (m.in. średnie, percentyle, histogramy

Tabela 2.1: Przykładowy zanonimizowany fragment zapisu telemetrycznego aktywności po eksporcie do postaci tabelarycznej.

Czas [s]	Moc [W]	Tętno [ud./min]	Kadencja [obr./min]	Dystans [km]	Wysokość [m]
0	87	108	56	0,000	55,0
1	81	108	56	0,005	55,0
2	45	109	56	0,010	55,0
3	26	110	56	0,015	55,0
4	25	110	56	0,020	55,0
5	1	110	56	0,025	55,0
6	6	110	21	0,030	55,0
7	47	110	42	0,035	52,6
8	52	110	48	0,040	51,4
9	24	111	47	0,044	51,4

Źródło: Opracowanie własne na podstawie danych GoldenCheetah OpenData (Liversedge, 2020).

intensywności, parametry tętna oraz wartości MMP) stanowiące bezpośrednie wejście dla modeli regresyjnych. O skali przetwarzania danych świadczy fakt, że w eksperymencie bazowym wykorzystano 151 399 sesji treningowych, a w dodatkowej próbie kontrolnej 979 672 sesje.

Uzasadnienie przetwarzania batchowego.

Zastosowanie przetwarzania batchowego wynikało z rozmiaru i struktury materiału źródłowego. Archiwa obejmują wiele plików sesji, a ich jednoczesne rozpakowanie zwiększałoby zapotrzebowanie na wolne miejsce dyskowe i utrudniało kontrolę przebiegu procesu. Praca porcjami pozwala ograniczyć liczbę aktywnie przetwarzanych danych oraz zapisywać wyniki pośrednie po zakończeniu kolejnej partii.

Podjęcie batchowe ma również znaczenie dla powtarzalności. Jeżeli pojedyncza paczka zawiera plik uszkodzony albo niezgodny z oczekiwaną strukturą, problem można odnotować i przeanalizować bez utraty wyników uzyskanych wcześniej. Etapy procesu stają się obserwowalne: możliwe jest porównanie liczby archiwów wejściowych, liczby odczytanych sesji oraz liczby rekordów zapisanych po filtracji. Ogranicza to ryzyko, że błąd pojedynczego przebiegu zostanie zauważony dopiero podczas modelowania.

2.3. Przygotowanie danych

Dane rejestrowane w warunkach terenowych mogą zawierać braki oraz artefakty wynikające z zakłóceń transmisji czujników, problemów z kalibracją urządzeń lub chwilowej utraty sygnału. Z tego względu przed etapem modelowania zastosowano filtrację oraz ekstrakcję zagregowanych cech opisujących sesję.

Jednostką analizy jest sesja treningowa, a nie pojedyncza próbka szeregu czasowego. Takie założenie odpowiada celowi pracy: model ma korzystać z podsumowania rutynowej aktywności i przewidywać wartość FTP przypisaną do tej aktywności. Próbkę sekundową służą do obliczenia cech, ale po agregacji nie są bezpośrednimi rekordami wejściowymi algorytmów regresyjnych.

Przetwarzanie sesji obejmuje rozpoznanie dostępności sygnałów, obliczenie czasu aktywności, statystyk mocy, tętna i kadencji oraz cech opisujących rozkład intensywności. Brak pojedynczego sygnału nie powinien automatycznie prowadzić do odrzucenia całej sesji, ponieważ część modeli może nadal wykorzystać pozostałe predyktory. Jednocześnie obecność braków jest informacją o jakości danych i wymaga jawnej obsługi na etapie przygotowania wejścia modelu. W niniejszej pracy ewentualne braki wartości w cechach wejściowych były uzupełniane bezpośrednio w potoku przetwarzania (pipeline) modeli. Zastosowano w tym celu strategię medianową przy użyciu klasy `SimpleImputer(strategy='median')`. Imputacja ta była wykonywana wyłącznie na cechach wejściowych (predyktorach), nigdy zaś na zmiennej celu. Zastosowanie tego mechanizmu miało na celu umożliwienie trenowania i wnioskowania modeli przy niepełnych odczytach telemetrycznych (np. w przypadku chwilowych przerw w rejestracji tętna), choć brak sygnału sam w sobie pozostaje istotnym ograniczeniem jakości danych.

Istotne jest także rozróżnienie zerowej mocy od brakującego pomiaru. Wartość równa zero może odpowiadać realnemu fragmentowi jazdy bez pedałowania, na przykład podczas zjazdu lub dojazdu do skrzyżowania. Brak odczytu oznacza natomiast, że informacja nie została zarejestrowana. Z perspektywy inżynierii cech sytuacje te mają odmienne znaczenie i nie powinny być automatycznie utożsamiane.

Filtracja wartości FTP.

Szczególną uwagę poświęcono wartości etykiety FTP. Zastosowano filtr

jakościowy:

$$50 \leq \text{ftp_label} \leq 500 \text{ W.} \quad (2.1)$$

Pozwoliło to odrzucić wartości skrajne, które mogły wynikać z błędów zapisu lub nieprawidłowego działania aparatury.

Filtr ma charakter jakościowy, a nie fizjologicznej diagnozy konkretnego rekordu. Jego zadaniem jest usunięcie wartości skrajnych, które mogłyby nieproporcjonalnie wpływać na trening modeli i metryki błędu. Nie rozstrzyga on, czy każda pozostawiona etykieta dokładnie odpowiada aktualnej dyspozycji zawodnika. Ocena tej kwestii wymagałaby audytu pojedynczych sesji lub niezależnego pomiaru referencyjnego.

2.4. Definicja zmiennej celu i etykietowanie

W zadaniu uczenia nadzorowanego do każdej sesji przypisano referencyjną wartość FTP. Etykietę wyznaczano heurystycznie na podstawie maksymalnej średniej mocy 20-minutowej:

$$\text{FTP}_{\text{ref}}^{(i)} = 0,95 \cdot \max(\bar{P}_{20 \text{ min}}(t)), \quad (2.2)$$

gdzie $\text{FTP}_{\text{ref}}^{(i)}$ oznacza referencyjne FTP dla sesji i , a $\max(\bar{P}_{20 \text{ min}}(t))$ jest najwyższą wartością 20-minutowej średniej kroczącej mocy zarejestrowaną w tej sesji. W zbiorze cecha ta występuje jako `mmp_20min`.

Tak zdefiniowana etykieta ma charakter heurystyczny i operacyjny: oznacza $\text{FTP} = 0,95 \times \text{MMP20}$ wyznaczone z profilu mocy w danych telemetrycznych, a nie laboratoryjnie zwalidowany próg fizjologiczny. Jest przydatna w analizie dużego zbioru historycznego, lecz nie zastępuje wyniku kontrolowanego badania laboratoryjnego. Bezpośredni związek etykiety z cechą `mmp_20min` wymaga również jawnej kontroli ryzyka data leakage (Kaufman i in., 2012; Bernett i in., 2024).


Maksymalna średnia krocząca mocy z okna 20-minutowego nie musi pochodzić z formalnego testu FTP. Może zostać zarejestrowana podczas interwału, wyścigu, dłuższego podjazdu albo innego fragmentu treningu. Z jednej strony zwiększa to możliwość automatycznego etykietowania danych historycznych. Z drugiej strony oznacza, że warunki uzyskania etykiety nie są jednolite: różnią się przygotowaniem zawodnika, profilem trasy, strategią wysiłku i motywacją.

Ryzyko etykietowania ma dwa wymiary. Pierwszy dotyczy trafności samego przelicznika 0,95, który nie musi jednakowo dobrze opisywać każdego zawodnika.

Drugi wynika z jakości pomiaru mocy i przebiegu konkretnej sesji. Wartość `ftp_label` należy więc interpretować jako operacyjną etykietę historyczną wykorzystywaną do prototypowej oceny pipeline'u, a nie jako bezbłędny pomiar fizjologiczny.

Ta definicja wyjaśnia rolę wariantu A. Jeżeli `mmp_20min` pozostaje w zbiorze predyktorów, zadanie regresyjne staje się w znacznej części odtworzeniem wzoru etykietującego. Taki wariant jest potrzebny jako kontrola ujawniająca skalę wycieku, ale nie odpowiada celowi estymacji na podstawie szerszego zestawu cech telemetrycznych.

Przykładowe profile najlepszej mocy średniej (MMP) dla wybranych anonimowych kolarzy, ilustrujące różnice w przebiegu profilu mocy oraz różnice poziomu mocy w krótkich i dłuższych przedziałach czasu, przedstawiono na rysunku 2.2. Wykres ten obrazuje przykładowy charakter krzywych MMP (zależność średniej mocy maksymalnej od czasu trwania wysiłku) oraz to, w jaki sposób cecha `mmp_20min` wyznacza wartość FTP operacyjnego.



Rysunek 2.2: Przykładowe profile mocy względem czasu trwania wysiłku

Źródło: Opracowanie własne na podstawie danych GoldenCheetah OpenData (Liversedge, 2020).

Wykres ten pełni rolę empirycznego tła metodologicznego: pokazuje różnorodność i indywidualną charakterystykę profili wydolnościowych u różnych kolarzy. Ilustruje to potrzebę uwzględnienia różnic w profilach podczas trenowania

modeli regresyjnych.

2.5. Inżynieria cech

Z szeregów czasowych wyznaczono zagregowane predyktory opisujące charakter sesji:

- **Cechy czasu i objętości:** czas aktywności, czas jazdy bez przestojów, dystans i przewyższenie.
- **Cechy mocy:** średnia moc, percentyle rozkładu mocy, moc znormalizowana oraz histogramy intensywności.
- **Cechy tętna:** wartości średnie, maksymalne i miary zmienności.
- **Cechy kadencji:** statystyki rytmu pedałowania oraz udział fragmentów jazdy bez generowania mocy.
- **Cechy odsprężenia tętna:** zmiany relacji pomiędzy mocą a tętnem w trakcie wysiłku.
- **Cechy Maximum Mean Power (MMP):** maksymalne średnie moce wyznaczane dla różnych długości okna czasowego, w tym `mmp_20min`.

Histogramy intensywności i udziały czasu w zakresach mocy zachowują więcej informacji niż pojedyncza średnia. Dwie sesje o tej samej średniej mocy mogą mieć zupełnie inny przebieg: jedna może być równą jazdą wytrzymałościową, a druga zbiorem krótkich interwałów rozdzielonych odpoczynkiem. Podobnie kwantyle rozkładu pozwalają odróżnić poziom typowego obciążenia od wartości osiąganych jedynie okresowo.

Cechy odsprężenia opisują zmianę relacji mocy do tętna w czasie. Jeżeli przy zbliżonym obciążeniu mechanicznym tętno stopniowo rośnie, może to wskazywać na dryf układu krążenia związany z czasem trwania wysiłku, temperaturą, odwodnieniem lub zmęčeniem. Wskaźniki te nie mają jednoznacznej interpretacji przyczynowej, lecz dostarczają modelowi informacji niedostępnej w samych statystykach mocy.

Cechy `mmp_*` opisują maksymalną średnią moc utrzymywaną w oknach o różnych długościach. Są użyteczne, ponieważ przybliżają kształt krzywej mocy zawodnika, ale wymagają szczególnej ostrożności. `mmp_20min` jest bezpośrednio używane podczas tworzenia etykiety i dlatego musi zostać usunięte z głównego

wariantu badawczego. Pozostałe cechy MMP nie są identyczne z etykietą, lecz nadal pozostają blisko powiązane z profilem wydolności. Z tego powodu oceniono także wariant konserwatywny bez całej tej grupy.

2.6. Warianty eksperymentalne

W celu oceny wpływu cech MMP oraz identyfikacji ryzyka data leakage przygotowano trzy warianty:

1. **Wariant A (kontrolny z ryzykiem data leakage):** zawiera cechę `mmp_20min`, z której bezpośrednio obliczana jest etykieta FTP. Wariant służy wyłącznie diagnozie skutków wycieku informacji.
2. **Wariant B (główny wariant badawczy):** zawiera 46 cech po usunięciu `mmp_20min`. Jest podstawą oceny jakości modeli.
3. **Wariant C (konserwatywny):** zawiera 41 cech po usunięciu wszystkich predyktorów z prefiksem `mmp_`. Pozwala ocenić przydatność pozostałych informacji telemetrycznych.

Wariant B usuwa bezpośredni składnik wzoru etykietującego, czyli `mmp_20min`, lecz nie eliminuje całej informacji wynikającej z krzywej mocy zawodnika. Inne cechy MMP, na przykład `mmp_10min` lub `mmp_30min`, mogą nadal pełnić funkcję silnych pośrednich proxy etykiety FTP. Z tego powodu wariant C potraktowano jako bardziej konserwatywną ocenę zdolności predykcyjnej cech pośrednich, niewykorzystujących bezpośrednio rodziny cech MMP.

Porównanie wariantów nie służy wyborowi dowolnego zestawu dającego najniższy błąd. Każdy wariant odpowiada odrębnemu pytaniu metodologicznemu. Wariant A pokazuje, jak wygląda rezultat obciążony data leakage. Wariant B sprawdza, czy po usunięciu bezpośredniej składowej etykiety zachowana zostaje wysoka jakość predykcji. Wariant C ocenia, ile informacji pozostaje w teledetrii po bardziej rygorystycznym usunięciu predyktorów związanych z krzywą MMP. Dopiero wspólna interpretacja trzech konfiguracji pozwala ocenić źródła jakości modelu.

2.7. Strategia podziału danych

Losowy podział pojedynczych rekordów mógłby prowadzić do sytuacji, w której sesje tego samego zawodnika znalazłyby się jednocześnie w zbiorze treningowym i testowym, co grozi wystąpieniem data leakage, konfundowaniem tożsamości i fałszywie optymistyczną oceną jakości na etapie walidacji (Kohavi, 1995; Saeb i in., 2017; Chaibub Neto i in., 2019; Tougui i in., 2021; Rosenblatt i in., 2024; Richter i in., 2021). Ograniczono to ryzyko przez zastosowanie mechanizmu `GroupShuffleSplit` (scikit-learn developers, 2026) z grupowaniem po identyfikatorze `athlete_id`. Każdy zawodnik został przypisany wyłącznie do jednego podzbioru. Finalny eksperyment wykorzystywał pojedynczy podział treningowy i testowy z parametrami `test_size=0.2` oraz `random_state=42`.


Stabilność wyników dla różnych składów próby testowej mogłaby zostać w przyszłości oceniona przez powtarzany `GroupShuffleSplit` lub `GroupKFold`. Obecny pojedynczy podział nadal jest właściwszy niż losowe mieszanie sesji, ponieważ ogranicza wyciek informacji osobniczej.

Zwykły losowy split byłby błędny z punktu widzenia docelowego zastosowania. Sesje jednej osoby są ze sobą powiązane: mają podobny zakres mocy, charakterystyczną relację mocy do tętna, powtarzalne trasy i nawyki treningowe. Umieszczenie części aktywności tej samej osoby w treningu i teście umożliwiłoby modelowi korzystanie z tego profilu. Metryki opisywałyby wówczas przewidywanie kolejnej sesji zawodnika częściowo znanego algorytmowi, a nie generalizację na nową osobę.

Rysunek 2.3 syntetycznie pokazuje różnicę pomiędzy losowym podziałem sesji a podziałem osobniczym. Diagram nie dodaje nowego wariantu eksperymentu, lecz porządkuje przyjęte zabezpieczenie metodologiczne.

Schemat ten graficznie porządkuje proces podziału danych, ułatwiając zrozumienie, dlaczego podział osobniczy chroni przed fałszywym zawyżeniem wyników walidacji.

Podział po `athlete_id` stawia przed modelem trudniejsze i bardziej użyteczne zadanie. Każda predykcja testowa dotyczy sesji zawodnika, którego dane nie były wykorzystywane podczas uczenia. Nie eliminuje to wszystkich źródeł błędu ani nie



Rysunek 2.3: Porównanie losowego podziału sesji i podziału osobniczego

Źródło: Opracowanie własne.

zastępuje walidacji na zbiorze zewnętrznym, ale ogranicza jeden z najważniejszych rodzajów wycieku w danych wielosesyjnych.

2.8. Modele i metryki oceny

W eksperymencie porównano trzy modele regresyjne:

- **Ridge Regression:** model liniowy z regularyzacją, pełniący funkcję punktu odniesienia (Hoerl i Kennard, 1970).
- **Random Forest:** model zespołowy oparty na uśrednianiu predykcji wielu drzew decyzyjnych (Breiman, 2001).
- **XGBoost:** implementacja Gradient Boosting, w której kolejne drzewa korygują błędy wcześniejszych predykcji (Chen i Guestrin, 2016).

Jako miary jakości wykorzystano Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), medianowy błąd bezwzględny (MedAE) oraz coefficient of determination (R^2). Metryki obliczano na zbiorze testowym złożonym z sesji zawodników nieobecnych w zbiorze treningowym (Chai i Draxler, 2014).

MAE jest podstawową miarą interpretowalną praktycznie, ponieważ opisuje przeciętną bezwzględną różnicę pomiędzy etykietą a predykcją w watach. RMSE również ma jednostkę watów, ale przez podnoszenie błędów do kwadratu silniej reaguje na większe pomyłki. Zestawienie obu miar pozwala zauważyć, czy poza typowymi błędami występują obserwacje wyraźnie trudniejsze dla modelu.

MedAE jest medianą bezwzględnych różnic i w mniejszym stopniu podlega wpływowi obserwacji odstających. Uzupełnia MAE, pokazując błąd typowy dla środkowej części rozkładu. Współczynnik R^2 informuje natomiast, jaka część zmienności etykiety jest odtwarzana przez predykcję względem prostego punktu odniesienia opartego na średniej. Nie należy interpretować go samodzielnie: wysoka wartość R^2 może współwystępować z data leakage, dlatego musi być analizowana łącznie z definicją cech, podziałem danych i błędem wyrażonym w watach.

2.9. Wykorzystane technologie i narzędzia

Implementację potoku przygotowano w języku Python. Do przetwarzania tabelarycznych danych sesji wykorzystano bibliotekę `pandas`, natomiast operacje numeryczne i obliczenia pomocnicze realizowano z użyciem biblioteki `NumPy`. Modele Ridge Regression i Random Forest, podział `GroupShuffleSplit`, imputację braków danych, standaryzację oraz obliczanie metryk regresyjnych zaimplementowano za pomocą biblioteki `scikit-learn` (Pedregosa i in., 2011). Model Gradient Boosting uruchamiano przy użyciu biblioteki `XGBoost`.

Wykresy wykorzystywane podczas analizy wyników generowano programowo z użyciem biblioteki `matplotlib`. Poszczególne etapy przygotowania danych i ewaluacji zostały rozdzielone pomiędzy skrypty potoku ETL. Taka organizacja pozwala powtarzać eksperymenty na tym samym zbiorze wejściowym, zachować jawne parametry podziału danych oraz odtworzyć kolejne etapy prowadzące od surowych archiwów do plików wynikowych.

2.10. Podsumowanie

Przyjęta metodologia umożliwia odtworzenie eksperymentu na podstawie przygotowanych skryptów i plików wynikowych. Kluczowe znaczenie mają dwa zabezpieczenia: osobniczy podział danych z wykorzystaniem `GroupShuffleSplit` oraz rozdzielenie wariantów A, B i C, które pozwala odróżnić wynik obciążony data leakage od głównego wyniku badawczego.

Należy podkreślić, że zmienna celu (`ftp_label`) ma charakter operacyjny i heurystyczny. Została zdefiniowana jako 0,95 maksymalnej średniej mocy 20-minutowej, a nie na podstawie kontrolowanego pomiaru laboratoryjnego. Model

estymuje zatem przyjętą etykietę FTP, nie bezpośrednio mierzony próg fizjologiczny, taki jak moc krytyczna czy maksymalny stan równowagi mleczanowej. Interpretacja wyników musi uwzględniać to ograniczenie: wysoka jakość predykcji oznacza dobre przybliżenie heurystycznej wartości referencyjnej, a nie równoważność z diagnostyką laboratoryjną.

Rozdział 3. Eksperymenty i wyniki

Rozdział przedstawia przebieg i wyniki eksperymentów, które weryfikują hipotezę badawczą oraz odpowiadają na pytania sformułowane we wstępie. Najpierw scharakteryzowano zbiór i konfigurację badania, a następnie porównano modele, warianty cech, rozkład błędów i ważność predyktorów.

Ocenie poddano zdolność modeli uczenia maszynowego do estymacji operacyjnej etykiety Functional Threshold Power (FTP) na podstawie danych telemetrycznych. Szczególną uwagę poświęcono ryzyku data leakage wynikającemu z bezpośredniego powiązania części cech wejściowych ze zmienną celu.

3.1. Charakterystyka przygotowanego zbioru danych

Po kontrolowanym przetwarzaniu wykorzystano dane z 781 archiwów ZIP ze zbioru GoldenCheetah OpenData. Zastosowano filtr wartości etykiety FTP: do eksperymentu dopuszczono wyłącznie sesje spełniające warunek $50 \leq \text{ftp_label} \leq 500$ W. Pozwoliło to odrzucić skrajne wartości odstające, które mogły wynikać z artefaktów lub błędów pomiarowych.

Finalny plik eksperymentalny obejmował 726 zawodników oraz 151 399 sesji treningowych. Zmienną celu stanowiła wartość `ftp_label`. Strukturę przygotowanego zbioru przedstawiono w tabeli 3.1.

Liczba sesji jest istotna z punktu widzenia uczenia modeli, ale nie oznacza pełnej niezależności obserwacji. Jeden zawodnik może dostarczać wiele aktywności realizowanych w różnych okresach. Z tego względu liczby rekordów nie należy utożsamiać z liczbą niezależnych osób. Właściwym zabezpieczeniem metodologicznym jest podział osobniczy opisany w kolejnej sekcji.

Tabela 3.1: Struktura przygotowanego zbioru danych wykorzystanego w eksperymentach

Element struktury	Charakterystyka
Źródło danych	Zanonimizowane sesje telemetryczne na podstawie 781 archiwów ZIP GoldenCheetah OpenData
Liczba zawodników	726
Liczba obserwacji przed filtrem	152 010 sesji treningowych
Liczba obserwacji po filtrze	151 399 sesji treningowych
Liczba odrzuconych wartości odstających	611 sesji treningowych
Zakres filtra FTP	$50 \leq ftp_label \leq 500$ W
Zmienna celu	<code>ftp_label</code>
Liczba cech wariantu B	46
Liczba cech wariantu C	41

Źródło: Opracowanie własne na podstawie przetworzonych danych GoldenCheetah OpenData.

3.2. Konfiguracja eksperymentu i podział danych

Zastosowano podział osobniczy (ang. *subject-wise split*) z wykorzystaniem mechanizmu `GroupShuffleSplit`. Identyfikator `athlete_id` pełnił rolę zmiennej grupującej, dzięki czemu wszystkie sesje danego zawodnika trafiały wyłącznie do jednego podzbioru. Test odbywał się zatem na zawodnikach nieobecnych w zbiorze treningowym.

Podział wykonano z parametrami `test_size=0.2` oraz `random_state=42`. Szczegółowe podsumowanie przedstawiono w tabeli 3.2.

Stała wartość `random_state` umożliwia odtworzenie przyjętego podziału. Finalna ocena dotyczy pojedynczego zbioru treningowego i testowego, a nie walidacji krzyżowej. Wyniki należy zatem interpretować jako rezultat konkretnej, jawnie zdefiniowanej ewaluacji historycznej. Podział po zawodniku ogranicza ryzyko zawyżenia metryk przez obecność sesji tej samej osoby po obu stronach eksperymentu.

Tabela 3.2: Podział danych na zbiór treningowy i testowy

Parametr	Wartość
Metoda podziału	GroupShuffleSplit (grupowanie po athlete_id)
Liczba rekordów (Train)	117 903
Liczba rekordów (Test)	33 496
Liczba zawodników (Train)	580
Liczba zawodników (Test)	146
Proporcja (Test Size)	0,2 (20%)

Źródło: Opracowanie własne na podstawie przetworzonych danych GoldenCheetah OpenData.

Porównano trzy warianty predyktorów:

- **Wariant A (kontrolny z ryzykiem data leakage):** zawierał cechę `mmp_20min`, z której wyliczana była etykieta `ftp_label`. Wariant służył wyłącznie diagnozie skutków wycieku informacji.
- **Wariant B (główny wariant badawczy):** zawierał 46 cech po usunięciu `mmp_20min`.
- **Wariant C (konserwatywny):** zawierał 41 cech po usunięciu wszystkich predyktorów z prefiksem `mmp_`.

3.3. Przebieg eksperymentów, modele i parametry

Na każdym z wariantów A, B i C uruchomiono trzy algorytmy regresyjne: Ridge Regression, Random Forest oraz XGBoost. Ridge Regression stanowił liniowy punkt odniesienia. Random Forest agregował predykcje wielu drzew decyzyjnych, natomiast XGBoost reprezentował rodzinę modeli Gradient Boosting, w których kolejne drzewa korygują błędy wcześniejszych elementów.

Porównanie trzech klas modeli umożliwia ocenę, czy w danych dominuje zależność możliwa do przybliżenia liniowo, czy też dodatkową wartość przynoszą algorytmy odwzorowujące nieliniowości i interakcje cech. Ridge Regression jest celowo prostym punktem odniesienia: po standaryzacji predyktorów dopasowuje liniową relację regularyzowaną karą ℓ_2 . Random Forest zmniejsza wariancję pojedynczego drzewa przez agregację wielu modeli budowanych na losowanych

danych i podzbiorach cech. XGBoost uczy kolejne drzewa sekwencyjnie, kierując je na błędy pozostawione przez wcześniejsze elementy zespołu.

Konfigurację modeli przedstawiono w tabeli 3.3. Dla każdego modelu obliczono metryki MAE, RMSE, R^2 oraz MedAE na tym samym zbiorze testowym. MAE i MedAE opisują typową wielkość błędu w watach, RMSE silniej uwzględnia większe pomyłki, a R^2 informuje o części wariancji etykiety wyjaśnianej przez model.

Tabela 3.3: Konfiguracja modeli wykorzystanych w eksperymencie

Model	Przetwarzanie wstępne	Najważniejsze parametry
Ridge Regression	SimpleImputer, StandardScaler	random_state=42
Random Forest	SimpleImputer	n_estimators=100, random_state=42, n_jobs=-1
XGBoost	Brak dodatkowego przetwarzania	n_estimators=100, random_state=42, objective=reg:squarederror, n_jobs=-1

Źródło: Opracowanie własne na podstawie skryptów uczenia maszynowego.

Warto zauważyć, że model Ridge Regression wymagał uprzedniej standaryzacji cech przy użyciu klasy `StandardScaler`, podczas gdy modele oparte na drzewach decyzyjnych (Random Forest oraz XGBoost) nie wymagały tego typu skalowania predyktorów. Algorytm lasu losowego (Random Forest) uczył się z parametrami `n_estimators=100`, `random_state=42` i `n_jobs=-1`. Model XGBoost skonfigurowano z parametrami `n_estimators=100`, `objective='reg:squarederror'`, `random_state=42` oraz `n_jobs=-1`. Wszystkie pozostałe parametry modeli, które nie zostały wymienione jawnie w tabeli 3.3, pozostawiono na poziomie domyślnym dla użytej wersji biblioteki (`scikit-learn` oraz `xgboost`). W badaniach nie prowadzono szerokiego strojenia hiperparametrów, ponieważ głównym celem było porównanie stabilnych konfiguracji bazowych modeli, a nie maksymalizacja metryk poprzez dedykowany tuning.

3.4. Wyniki predykcji dla wariantów A, B i C

Zestawienie wyników przedstawiono w tabeli 3.4. Wariant A prowadzi do niemal idealnego dopasowania, ponieważ zawiera predyktor bezpośrednio związany ze sposobem obliczania etykiety. Nie stanowi więc wyniku badawczego, lecz kontrolę ujawniającą data leakage. Podstawą interpretacji są warianty B i C.

Układ tabeli pozwala porównać dwa wymiary eksperymentu. Wiersze w obrębie jednego wariantu pokazują różnice pomiędzy algorytmami przy niezmienionej informacji wejściowej. Porównanie tych samych modeli pomiędzy wariantami ujawnia natomiast wpływ usuwania cech powiązanych z MMP. Taki sposób prezentacji zapobiega wyciąganiu wniosku na podstawie pojedynczej metryki najlepszego modelu.

Tabela 3.4: Zbiorcze wyniki predykcji FTP na zbiorze testowym dla wariantów A, B i C

Wariant	Model	MAE [W]	RMSE [W]	R^2	MedAE [W]
A (kontrolny)	Ridge Regression	0,00	0,00	1,0000	0,00
A (kontrolny)	Random Forest	0,00	0,02	1,0000	0,00
A (kontrolny)	XGBoost	0,31	0,87	0,9997	0,18
B (główny)	Ridge Regression	7,06	10,33	0,9579	4,64
B (główny)	Random Forest	6,62	9,81	0,9619	4,38
B (główny)	XGBoost	6,55	9,68	0,9630	4,33
C (konserwatywny)	Ridge Regression	12,79	17,60	0,8776	9,79
C (konserwatywny)	Random Forest	10,36	14,80	0,9134	7,42
C (konserwatywny)	XGBoost	10,29	14,49	0,9170	7,34

Źródło: Opracowanie własne na podstawie wyników modeli; próba testowa obejmowała 33 496 sesji.

3.5. Porównanie i interpretacja modeli

W głównym wariancie badawczym B najlepszy wynik uzyskał XGBoost: MAE wyniosło 6,55 W, RMSE 9,68 W, a $R^2 = 0,9630$. Wyniki wskazują na wysoką jakość predykcji na historycznym zbiorze testowym. Należy jednak pamiętać, że wartość referencyjna FTP ma charakter heurystyczny, a model nie przeszedł walidacji prospektywnej.

Różnice pomiędzy modelami w wariancie B są niewielkie, ale spójne. Ridge

Regression osiągnął $MAE = 7,06$ W, Random Forest $MAE = 6,62$ W, a XGBoost $MAE = 6,55$ W. Konkurencyjny wynik regresji Ridge wskazuje, że istotna część relacji pomiędzy cechami a etykietą może być opisana liniowo po odpowiednim przygotowaniu danych. Poprawa uzyskana przez modele drzewiaste sugeruje jednocześnie obecność nieliniowości lub interakcji cech, które są użyteczne predykcyjnie.

W wariancie A bardzo niski błąd nie jest cechą pożądaną w sensie badawczym. Wynika z konstrukcji datasetu: predyktor `mmp_20min` niemal bezpośrednio koduje wartość `ftp_label`. Szczególnie widoczny jest wynik Ridge Regression równy $MAE = 0,00$ W i $R^2 = 1,0000$. Model nie odkrywa w tym przypadku ogólnej relacji pomiędzy telemetrią a FTP, lecz odtwarza wzór użyty podczas etykietowania. Wariant A stanowi praktyczną demonstrację, dlaczego audyt cech jest konieczny nawet wtedy, gdy metryki wyglądają bardzo korzystnie.


W wariancie C usunięcie wszystkich cech `mmp_*` zwiększyło błąd najlepszego modelu do $MAE = 10,29$ W oraz $RMSE = 14,49$ W. Rezultaty sugerują, że cechy MMP inne niż `mmp_20min` zawierają istotną informację predykcyjną, ale również bardziej konserwatywny wariant pozwala uzyskać orientacyjne przybliżenie etykiety FTP.

Spadek jakości pomiędzy wariantami B i C jest oczekiwany, ponieważ cechy MMP opisują fragment krzywej mocy zawodnika. Po ich usunięciu model musi opierać się na informacjach bardziej pośrednich: kwantylach mocy, rozkładzie intensywności, czasie trwania wysiłku oraz relacji mocy do tętna. Wzrost MAE z $6,55$ W do $10,29$ W nie oznacza, że wariant C jest nieudany. Pokazuje koszt przyjęcia bardziej rygorystycznej definicji estymacji opartej na telemetrii rutynowych sesji oraz skalę informacji zawartej w cechach `mmp_*`.

W praktycznej interpretacji $MAE = 6,55$ W oznacza, że dla sesji zawodników testowych bezwzględna różnica pomiędzy predykcją wariantu B a historyczną etykietą wynosiła średnio około siedmiu watów. Dla wariantu C analogiczna wartość wyniosła $10,29$ W. Są to błędy względem etykiety heurystycznej, a nie względem pomiaru laboratoryjnego. Nie należy ich również traktować jako gwarantowanej granicy błędu pojedynczej prognozy: część obserwacji ma pomyłki większe, co sygnalizują wartości $RMSE$.

Porównanie wartości MAE na rysunku 3.1 pokazuje różnicę pomiędzy sztucznie zaniżonym błędem wariantu A a bardziej realistycznymi wynikami wariantów B i


C. Rysunek 3.2 przedstawia analogiczne zestawienie współczynnika R^2 ; głównym wnioskiem jest utrzymanie wysokiej jakości predykcji wariantu B po usunięciu bezpośredniego źródła data leakage.



Rysunek 3.1: Porównanie wartości MAE między wariantami i modelami

Źródło: Opracowanie własne na podstawie przeprowadzonych eksperymentów.

Zestawienie to wizualnie podsumowuje metryki z tabeli 3.4. Pozwala ono na szybką ocenę wzajemnych relacji pomiędzy wariantami i algorytmami, uwypuklając utratę dokładności po eliminacji wszystkich cech z rodziny MMP w wariancie C.



Rysunek 3.2: Porównanie współczynnika determinacji między wariantami i modelami

Źródło: Opracowanie własne na podstawie przeprowadzonych eksperymentów.


3.6. Analiza rozkładu błędów

Dla modelu XGBoost w wariacie B przeanalizowano relację pomiędzy wartościami przewidywanymi i referencyjnymi oraz rozkład błędów. Rysunek 3.3 pozwala ocenić skupienie predykcji wokół linii idealnego dopasowania, natomiast rysunek 3.4 przedstawia częstotliwość błędów o różnej wielkości.

Punkty na rysunku 3.3 skupiają się wokół linii idealnej predykcji, co jest zgodne z wartościami MAE i R^2 . Wykres nie zastępuje jednak osobnej analizy błędów dla poszczególnych grup zawodników.

Rozkład błędów na rysunku 3.4 jest skupiony w pobliżu zera. Wartość MAE równa 6,55 W oznacza, że w historycznym zbiorze testowym przeciętna różnica pomiędzy etykietą i predykcją była relatywnie mała, choć jej znaczenie praktyczne zależy od poziomu sportowego zawodnika. Nie oznacza to jednak, że każda pojedyncza prognoza jest obciążona błędem tej samej wielkości.

Histogram błędów uzupełnia wykres predykcji względem etykiety. Pozwala zobaczyć, czy większość różnic koncentruje się blisko zera i czy występują ogony rozkładu związane z trudniejszymi przypadkami. Ponieważ przedstawiona analiza dotyczy wszystkich sesji testowych łącznie, wymaga uzupełnienia o rozwarstwienie



Rysunek 3.3: Rzeczywiste i przewidywane wartości FTP dla modelu XGBoost

Źródło: Opracowanie własne na podstawie przeprowadzonych eksperymentów.

według poziomu etykiety FTP.

Uzupełniające zestawienie błędów według zakresów referencyjnej etykiety FTP przedstawiono w tabeli 3.5. Analiza dotyczy najlepszego modelu wariantu B, czyli XGBoost, i wykorzystuje te same obserwacje testowe co główna ewaluacja.


Tabela 3.5: Błędy predykcji modelu XGBoost w wariantcie B według zakresów referencyjnej etykiety FTP

Zakres FTP	Liczba sesji	Liczba zawodników	MAE [W]	MAPE [%]
< 150 W	5 971	123	4,41	3,73
150–250 W	22 856	142	6,31	3,18
250–350 W	4 615	84	10,34	3,69
≥ 350 W	54	9	19,37	5,23

Źródło: Opracowanie własne na podstawie pliku predykcji testowych

baseline_predictions_variant_b.csv.

Wartości bezwzględne błędu rosną wraz z poziomem FTP, co jest spodziewane przy większej skali mocy. Po przeliczeniu na błąd względny większość zakresów



Rysunek 3.4: Rozkład błędów modelu XGBoost w wariancie B

Źródło: Opracowanie własne na podstawie przeprowadzonych eksperymentów.


pozostaje na poziomie około 3–4%, natomiast najwyższy przedział ma zarówno największy MAE, jak i największy MAPE. Ostatni zakres obejmuje jednak tylko 54 sesje od 9 zawodników, dlatego należy traktować go jako sygnał wymagający dalszej weryfikacji, a nie jako stabilną charakterystykę całej populacji silniejszych kolarzy.

3.7. Znaczenie i ważność cech predykcyjnych

Modele drzewiaste umożliwiają analizę względnej ważności cech. Miara ta opisuje wkład predyktorów w decyzje modelu, ale nie pozwala wnioskować o związku przyczynowo-skutkowym. Bardziej szczegółową interpretację predykcji uzupełniono pomocniczą analizą metodą SHAP (Lundberg i Lee, 2017), której wyniki dla wariantu C omówiono w dalszej części rozdziału. Rysunki 3.5 i 3.6 przedstawiają 20 najważniejszych predyktorów dla modeli XGBoost odpowiednio w wariancie B i C.

Ważność cech należy traktować jako narzędzie diagnostyczne modelu, a nie ranking mechanizmów fizjologicznych. Predyktory mogą być ze sobą skorelowane, przez co informacja przypisana jednej zmiennej mogłaby zostać częściowo przejęta

przez inną po zmianie zestawu wejściowego. Wysoka pozycja cechy nie dowodzi również, że jej zmiana wywoła zmianę FTP. Pokazuje jedynie, że algorytm korzystał z niej podczas budowania predykcji w analizowanym zbiorze.




Rysunek 3.5: Ważność cech modelu XGBoost w wariancie B

Źródło: Opracowanie własne.

W wariancie B dominowała cecha `mmp_10min`, co jest spójne z bliskim powiązaniem maksymalnej mocy z 10 minut z mocą z 20 minut, która służy do wyznaczania operacyjnej etykiety FTP. Znaczenie miały również ogólne statystyki mocy oraz cechy opisujące rozkład intensywności sesji. Dominacja cech typu MMP w wariancie B wskazuje, że samo usunięcie cechy `mmp_20min` eliminuje bezpośredni data leakage, lecz nie zapobiega korzystaniu przez model z cech bezpośrednio sąsiadujących na krzywej profilu mocy. W rezultacie wariant B należy interpretować jako model, który wciąż pośrednio opiera się na informacjach o profilu maksymalnych możliwości kolarza, a nie wyłącznie na szerszej charakterystyce treningowej.

Po usunięciu całej rodziny cech `mmp_*` w wariancie C model opierał się w większym stopniu na kwantylach mocy (takich jak `power_p75`), udziale czasu w strefach intensywności oraz relacji tętna do mocy. Zestawienie to wskazuje, że model potrafi efektywnie wykorzystać sygnał rozproszony w pozostałych predyktorach telemetrycznych. Wariant C stanowi więc bardziej konserwatywną metodologicznie



Rysunek 3.6: Ważność cech modelu XGBoost w wariancie C

Źródło: Opracowanie własne.

próbę oceny potencjału predykcyjnego parametrów sesji treningowych, uniezależnioną od bezpośrednich wskaźników maksymalnych możliwości wysiłkowych zawodnika.


Zmiana rankingu pomiędzy wariantami B i C jest istotna metodologicznie. Sugeruje ona, że dataset zawiera informacje zdatne do predykcji rozproszone w kilku grupach cech, a wykluczenie cech o charakterze bezpośredniego wycieku skłania model do korzystania z alternatywnych korelacji (np. relacji mocy i tętna). Jednocześnie sam ranking ważności cech nie pozwala jednoznacznie rozstrzygnąć o stabilności tych zależności w innych zbiorach danych, co motywuje przeprowadzenie dodatkowej weryfikacji.

Pomocnicza analiza interpretowalności SHAP dla wariantu C.

W celu dokładniejszego opisu zachowania modeli i kierunku wpływu poszczególnych zmiennych na predykcje przeprowadzono pomocniczą analizę interpretowalności SHAP (*SHapley Additive exPlanations*) (Lundberg i Lee, 2017). Analizę tę zrealizowano jako uzupełnienie eksploracyjne dla modeli XGBoost trenowanych w ramach najbardziej konserwatywnego wariantu C (w którym całkowicie wykluczono rodzinę cech `mmp_*`). Ze względów wydajnościowych obliczenia wartości SHAP wykonano na losowej próbie 1500 obserwacji pobranych ze zbioru testowego,

zachowując ten sam osobniczy podział danych po identyfikatorze `athlete_id`.

Wykres typu *beeswarm* (podsumowanie wartości SHAP) przedstawiono na rysunku 3.7. Każdy punkt na wykresie odpowiada pojedynczej sesji treningowej ze zbioru testowego. Pozycja punktu na osi poziomej wskazuje, czy dana cecha podwyższała (wartości dodatnie), czy obniżała (wartości ujemne) predykcję progu FTP w watach. Kolor punktu (od niebieskiego do czerwonego) reprezentuje względną wartość danej cechy (od niskiej do wysokiej).



Rysunek 3.7: Wykres beeswarm SHAP dla modelu XGBoost w wariantcie C

Źródło: Opracowanie własne na podstawie analizy SHAP.

Wizualizacja SHAP pozwala opisać, które zmienne współkształtują predykcję FTP na poziomie pojedynczych treningów. Wyniki te sugerują następujące zależności:

- Cechy opisujące typowy i wyższy poziom generowanej mocy, czyli `power_p75` (75. percentyl mocy) oraz `mean_power` (średnia moc), posiadają dominujący, dodatni wpływ na predykcję. Wysokie wartości tych cech (punkty czerwone) przesuwają predykcję w kierunku wyższych watów, co jest spójne z operacyjną definicją etykiety FTP.

- Cecha opisująca odsprężenie tętna i mocy (`power_hr_decoupling_pct`) wykazuje również zauważalny wpływ. Model przypisuje wyższy wpływ (punkty czerwone) sesjom o wyższym odsprężeniu, co może oznaczać, że w tym zbiorze takie sesje współwystępowały z wyższymi wartościami operacyjnej etykiety FTP.
- Bardzo wyraźną ujemną zależność można zaobserwować dla cechy `median_hr` (mediana tętna). Przy tych samych poziomach wygenerowanej mocy, wysokie tętno medianowe (punkty czerwone) obniża predykcję FTP, natomiast niskie tętno medianowe (punkty niebieskie) ją podwyższa. Zależność ta może być zgodna z interpretacją dotyczącą odpowiedzi krążeniowej organizmu, ale wymaga niezależnej walidacji i nie powinna być traktowana jako dowód mechanizmu fizjologicznego.

W celu weryfikacji stabilności zachowania modeli w zależności od przyjętego wariantu cech oraz skali danych, przeprowadzono dwie dodatkowe, pomocnicze analizy SHAP o charakterze kontrolnym.

Po pierwsze, obliczenia SHAP wykonane dla modelu wariantu B na zbiorze bazowym wskazały dominację cechy `mmp_10min` ze średnim bezwzględnym wpływem na poziomie 32,74 W. Druga najważniejsza cecha w tym rankingu (`mean_power`) wykazała wpływ wynoszący 3,69 W. Wynik ten sugeruje, że po wykluczeniu `mmp_20min` model wariantu B wciąż w dużym stopniu opiera swoje predykcje na sąsiadujących interwałach krzywej mocy maksymalnej, co czyni go zależnym od informacji o maksymalnych wysiłkach. Z tego powodu wariant C stanowi potrzebny punkt odniesienia: po odrzuceniu całej rodziny cech `mmp_*` model musi korzystać z bardziej zróżnicowanej telemetrii treningowej, np. relacji mocy i tętna.

Po drugie, analogiczną analizę SHAP wykonano dla modelu wariantu C na rozszerzonej próbie kontrolnej 5000 archiwów ZIP. Ponieważ dotyczy ona bezpośrednio eksperymentu skalowalności, jej tabelaryczne zestawienie i osobny ranking cech przedstawiono w sekcji 3.8.

Przedstawione analizy interpretowalności mają charakter pomocniczy i opisują wyłącznie strukturę decyzji podjętych przez algorytm XGBoost w zdefiniowanych wariantach eksperymentalnych. Wyniki SHAP dostarczają informacji o zachowaniu modelu, ale nie mogą być traktowane jako niezależny dowód na występowanie

określonych mechanizmów fizjologicznych u badanych kolarzy ani nie eliminują ograniczeń wynikających z heurystycznego charakteru etykiety FTP.

3.8. Dodatkowa próba kontrolna skalowalności

Po zakończeniu eksperymentu bazowego wykonano dodatkową próbę kontrolną na rozszerzonym zbiorze GoldenCheetah OpenData obejmującym 5000 archiwów ZIP. Celem tej próby nie było zastąpienie eksperymentu głównego, lecz sprawdzenie, czy ten sam potok przetwarzania pozostaje stabilny przy większej skali danych oraz czy najważniejsze obserwacje z mniejszej próby nie są skutkiem przypadkowej struktury konkretnego podzbioru. Próba kontrolna pełni zatem funkcję testu skalowalności i powtarzalności w ramach tego samego źródła danych.

W próbie kontrolnej zachowano tę samą definicję etykiety FTP, ten sam filtr wartości referencyjnej, te same warianty cech A/B/C, te same klasy modeli oraz ten sam sens podziału po identyfikatorze `athlete_id`. Modele były więc oceniane na sesjach zawodników niewystępujących w zbiorze treningowym, tak jak w eksperymencie bazowym. Po filtracji FTP zbiór kontrolny obejmował 4645 zawodników i 979 672 sesje treningowe. Porównanie skali eksperymentu bazowego i próby kontrolnej przedstawiono w tabeli 3.6.

Tabela 3.6: Porównanie skali eksperymentu bazowego i próby kontrolnej

Element	Eksperyment bazowy	Próba kontrolna
Liczba archiwów ZIP	781	5000
Liczba zawodników po filtrze FTP	726	4645
Liczba sesji po filtrze FTP	151 399	979 672
Najlepszy model wariantu B	XGBoost	Random Forest
Najlepsze MAE wariantu B	6,55 W	6,01 W
Najlepsze R^2 wariantu B	0,9630	0,9679

Źródło: Opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.

W wariancie A ponownie uzyskano niemal idealne metryki. Powtórzenie tego

zjawiska na większej próbie wzmacnia interpretację przedstawioną wcześniej: konfiguracja A jest obciążona ryzykiem data leakage, ponieważ zawiera cechę bezpośrednio związaną ze sposobem wyznaczania etykiety `ftp_label`. Z tego powodu wariant A pozostaje wariantem diagnostycznym, pokazującym skalę problemu, a nie właściwą oceną zdolności generalizacji modelu.


Najważniejszym praktycznie wariantem pozostaje wariant B, w którym usunięto bezpośrednio źródło wycieku, czyli cechę `mmp_20min`. W próbie kontrolnej najlepszy wynik wariantu B uzyskał model Random Forest: $MAE = 6,01$ W oraz $R^2 = 0,9679$. Jest to wynik zbliżony do jakości uzyskanej w eksperymencie bazowym i wskazuje, że procedura uczenia oraz oceny zachowuje stabilność przy większej liczbie archiwów. Wariant C, po usunięciu całej grupy cech `mmp_*`, osiągnął niższą jakość, ale nadal zachował wysoką zdolność odtwarzania operacyjnej etykiety FTP. Oznacza to, że w pozostałych cechach telemetrycznych nadal występuje sygnał predykcyjny, choć usunięcie informacji o maksymalnych mocach pogarsza dokładność.

Dodatkowo dla wariantu C na rozszerzonej próbie kontrolnej 5000 archiwów ZIP przeprowadzono pomocniczą analizę interpretowalności SHAP. Jej celem było sprawdzenie, czy ranking najważniejszych cech pozostaje zbliżony do wyników uzyskanych na zbiorze bazowym mimo istotnego zwiększenia liczby zawodników i sesji treningowych. Zestawienie pięciu najważniejszych cech według średnich bezwzględnych wartości SHAP przedstawiono w tabeli 3.7, a pełniejszy ranking dla próby kontrolnej zilustrowano na rysunku 3.8.

Tabela 3.7: Porównanie najważniejszych cech według średnich bezwzględnych wartości SHAP dla modelu XGBoost w wariantie C na zbiorze bazowym oraz próbie kontrolnej 5000 archiwów ZIP

Poz.	Cecha (zbiór bazowy)	Śr. SHAP [W]	Cecha (próba 5000)	Śr. SHAP [W]
1	<code>power_p75</code>	20,80	<code>power_p75</code>	22,08
2	<code>mean_power</code>	9,45	<code>mean_power</code>	9,91
3	<code>power_hr_decoupling_pct</code>	3,56	<code>high_intensity_fraction</code>	5,16
4	<code>high_intensity_fraction</code>	3,52	<code>power_hr_decoupling_pct</code>	3,94
5	<code>distance_km</code>	3,31	<code>duration_sec</code>	3,65

Źródło: Opracowanie własne na podstawie pomocniczej analizy SHAP.




Rysunek 3.8: Ranking cech SHAP wariantu C w próbie kontrolnej

Źródło: Opracowanie własne na podstawie analizy SHAP.

Wyniki wskazują, że również w większej próbie najwyższą rangę zachowały cechy opisujące rozkład mocy w sesji, w szczególności `power_p75` oraz `mean_power`. Zbieżność z rankingiem uzyskanym na zbiorze bazowym wspiera interpretację wariantu C jako bardziej konserwatywnego i stabilnego względem zmian liczebności próby. Jednocześnie analiza SHAP opisuje zachowanie modelu predykcyjnego, a nie stanowi bezpośredniej walidacji fizjologicznej.

Rysunek 3.9 porównuje metryki MAE i R^2 dla wariantów B i C w eksperymencie bazowym oraz w próbie kontrolnej. Wariant A pominięto na wykresie, ponieważ jego bardzo niskie błędy wynikają z bezpośredniego data leakage z cechy `mmp_20min`.

Dodatkową ocenę zachowania najlepszego sensownego wariantu przedstawiono na rysunkach 3.10 i 3.11. Wykres wartości przewidywanych względem referencyjnych pokazuje, że obserwacje koncentrują się w pobliżu linii idealnej zgodności, zarówno w eksperymencie bazowym, jak i w próbie kontrolnej. Nie oznacza to jednak niezależnego potwierdzenia fizjologicznej trafności etykiety FTP, lecz wskazuje na powtarzalne




Rysunek 3.9: Porównanie eksperymentu bazowego i próby kontrolnej

Źródło: Opracowanie własne na podstawie zapisanych wyników eksperymentów.


zachowanie modelu względem przyjętej etykiety operacyjnej.

Wykres reszt pozwala ocenić, czy błędy predykcji mają charakter systematyczny względem poziomu FTP. Rozrzut błędów wokół linii zerowej jest zgodny z interpretacją metryk zagregowanych: próba kontrolna nie zastępuje eksperymentu bazowego, ale wskazuje na stabilność zachowania modelu przy większej skali danych.



Rysunek 3.10: Wartości rzeczywiste i przewidywane FTP w próbie kontrolnej

Źródło: Opracowanie własne na podstawie przeprowadzonych eksperymentów.



Rysunek 3.11: Rozkład błędów predykcji FTP w próbie kontrolnej

Źródło: Opracowanie własne na podstawie przeprowadzonych eksperymentów.

Wyniki próby kontrolnej są zgodne z główną interpretacją pracy: usunięcie `mmp_20min` ogranicza bezpośredni data leakage, wariant B pozostaje najsilniejszą praktyczną konfiguracją, a wariant C pokazuje koszt bardziej konserwatywnego usunięcia całej grupy cech MMP. Jednocześnie większa skala danych nie usuwa ograniczeń definicji etykiety. Próba kontrolna nadal pochodzi z tego samego źródła GoldenCheetah OpenData, a wartość FTP nadal jest rekonstruowana z danych historycznych, nie zaś mierzona w kontrolowanym teście laboratoryjnym. Z tego powodu wyników kontrolnych nie należy interpretować jako niezależnego dowodu precyzyjnej predykcji fizjologicznej. Ich główna wartość polega na zwiększeniu wiarygodności technicznej i sprawdzeniu, czy podstawowa interpretacja wariantów A/B/C utrzymuje się przy większej skali danych.

3.9. Podsumowanie uzyskanych rezultatów

Celem eksperymentu była ocena jakości estymacji operacyjnej etykiety FTP oraz identyfikacja ryzyka data leakage. Wariant A pokazał, że włączenie `mmp_20min` prowadzi do sztucznie zawyżonych wyników i nie może stanowić podstawy oceny rozwiązania. W głównym wariancie B najlepszy był XGBoost z $MAE = 6,55$ W i $R^2 = 0,9630$. Wariant C, po usunięciu wszystkich cech `mmp_*`, uzyskał wyższy błąd, ale nadal pozwalał odtworzyć znaczną część wariancji etykiety FTP.

Podział osobniczy sprawił, że wszystkie modele oceniano na sesjach zawodników nieobecnych w zbiorze treningowym. Ogranicza to ryzyko, że algorytm odtwarza charakterystyczny profil konkretnej osoby zamiast uczyć się relacji możliwych do uogólnienia. Zbliżone rezultaty XGBoost i Random Forest w wariancie B wskazują również, że wysoka jakość predykcji nie zależy wyłącznie od jednego algorytmu.

Wariant C pełni ważną funkcję interpretacyjną. Wzrost MAE z 6,55 W do 10,29 W pokazuje, że cechy MMP inne niż `mmp_20min` niosą istotną informację o wydolności zawodnika. Jednocześnie utrzymanie $R^2 = 0,9170$ po ich usunięciu sugeruje, że model może wykorzystywać także rozkład intensywności, kwantyle mocy oraz cechy relacji mocy do tętna.

Błąd wyrażony w watach należy interpretować jako średnią różnicę pomiędzy predykcją a heurystyczną etykietą historyczną. MAE nie wyznacza maksymalnej pomyłki dla pojedynczej sesji i nie potwierdza równoważności z kontrolowanym

badaniem laboratoryjnym. Wyniki wskazują jednak, że dane telemetryczne mogą być użyteczne w narzędziu wspomagającym monitorowanie formy. Przed wykorzystaniem rozwiązania w praktyce potrzebna jest walidacja prospektywna.

Rozdział 4. Ocena rozwiązania, zastosowanie praktyczne i dyskusja

Rozdział łączy wyniki eksperymentów z celem praktycznym pracy. Omówiono w nim, co uzyskane metryki oznaczają dla monitorowania formy kolarskiej, czego na ich podstawie nie można rozstrzygnąć oraz w jakich warunkach rozwiązanie mogłoby wspierać zawodnika, trenera lub platformę analityczną.

Interpretacja uwzględnia ograniczenia danych historycznych i heurystyczny sposób wyznaczania etykiety FTP. W dalszej części przedstawiono także ryzyka wdrożenia oraz zasady komunikowania niepewności.

4.1. Interpretacja uzyskanych wyników

Analiza wyników przedstawionych w rozdziale trzecim wskazuje, że zestaw 46 zagregowanych cech telemetrycznych wariantu B zawiera informację pozwalającą szacować operacyjną etykietę FTP bez wykorzystania cechy `mmp_20min`. Najlepszy wynik uzyskał XGBoost: $R^2 = 0,9630$ oraz $MAE = 6,55$ W. Random Forest osiągnął zbliżoną jakość, natomiast Ridge Regression stanowił konkurencyjny liniowy punkt odniesienia. Dla porównania Vos i in. (2025) uzyskali $R^2 \approx 0,875$ przy predykcji czasu przejazdu 4 km na podstawie danych fizjologicznych i obciążenia treningowego z zastosowaniem GLM i Random Forest na próbie 27 zawodników. Wyższy współczynnik determinacji w niniejszej pracy może wynikać z większej próby (726 zawodników) oraz bezpośredniego związku cech MMP z etykietą FTP, co wymaga ostrożności przy porównywaniu obu podejść.

Wariant C miał charakter konserwatywny. Po usunięciu wszystkich cech `mmp_*` jakość predykcji spadła, lecz XGBoost nadal uzyskał $R^2 = 0,9170$ oraz $MAE = 10,29$ W. Wynik ten sugeruje, że informacja o FTP jest częściowo zawarta również w innych grupach cech, takich jak rozkład intensywności, statystyki mocy, tętna i kadencji.

Różnica pomiędzy wariantami B i C pokazuje kompromis pomiędzy jakością predykcji a rygorystycznym ograniczeniem informacji wejściowej. Usunięcie predyktora `mmp_20min` w wariancie B eliminuje bezpośrednie ryzyko data leakage, jednak pozostałe cechy MMP z sąsiednich okien czasowych (np. `mmp_10min` czy `mmp_30min`)

nadal skutecznie opisują ogólny kształt krzywej mocy zawodnika. Z tego powodu wariant B należy interpretować jako praktyczny wariant pozbawiony bezpośredniej składowej etykiety, lecz wciąż częściowo zależny od skorelowanego profilu mocy. Z kolei wariant C stanowi bardziej konserwatywną ocenę zdolności predykcyjnej modelu po całkowitym usunięciu rodziny cech MMP, co skłania algorytm do opierania się na bardziej rozproszonej telemetrii.

Wynik wariantu A nie może być interpretowany jako dowód jakości modelu. Niemal idealne dopasowanie jest skutkiem obecności `mmp_20min`, czyli predyktora bezpośrednio związanego ze sposobem wyznaczania etykiety. Wariant A pełni wyłącznie funkcję kontrolną.

4.2. Ocena rozwiązania w kontekście postawionych celów

Opracowane rozwiązanie należy oceniać w odniesieniu do celów sformułowanych we wstępie. W zakresie celu poznawczego usystematyzowano informacje dotyczące FTP, mocy krytycznej, progów metabolicznych oraz metod uczenia maszynowego stosowanych w analizie telemetrii sportowej.

W zakresie celu metodologicznego przygotowano potok przetwarzania danych obejmujący ekstrakcję, filtrację i inżynierię cech. Eksperyment przeprowadzono na 151 399 sesjach 726 zawodników z zastosowaniem podziału osobniczego, ograniczającego ryzyko przenikania sesji tej samej osoby pomiędzy zbiorem treningowym i testowym.

W zakresie celu użytecznego wyniki sugerują, że system może pełnić funkcję pomocniczą w monitorowaniu formy. Nie powinien być traktowany jako zamiennik diagnostyki laboratoryjnej ani jako samodzielne narzędzie podejmujące decyzje treningowe.

4.3. Znaczenie uczenia maszynowego w estymacji FTP

Klasyczne testy FTP są wartościowe, ale wymagają zaplanowanego wysiłku o wysokiej intensywności. Dane telemetryczne z rutynowych treningów pozwalają analizować dyspozycję zawodnika częściej i bez wprowadzania dodatkowej jednostki testowej. Modele uczenia maszynowego mogą agregować wiele sygnałów jednocześnie, uwzględniając zależności nieliniowe trudne do opisanego prostym

wzorem.

Praktyczne znaczenie takiej estymacji polega przede wszystkim na wspomaganiu obserwacji trendu. Pojedyncza prognoza powinna być interpretowana łącznie z historią treningów, samopoczuciem zawodnika oraz jakością danych z czujników.

Podjęcie oparte na danych ma szczególną wartość wtedy, gdy uzupełnia, a nie eliminuje inne źródła informacji. Okresowy test terenowy lub laboratoryjny może pełnić rolę punktu kontrolnego, natomiast estymacja pasywna pozwala obserwować okres pomiędzy takimi pomiarami. Jeżeli trend modelu i subiektywna ocena zawodnika zaczynają się wyraźnie rozchodzić, sytuacja ta powinna prowadzić do weryfikacji danych albo wykonania testu referencyjnego, a nie do automatycznej aktualizacji planu.

4.4. Ograniczenia przeprowadzonego badania

Pierwsze ograniczenie wiąże się z definicją wartości referencyjnej. Etykieta FTP ma charakter heurystyczny i bazuje na 95% maksymalnej średniej mocy 20-minutowej, przez co nie została potwierdzona jednolitym protokołem laboratoryjnym. Ograniczenie to jest zgodne z literaturą wskazującą, że proste przeliczenie wyniku 20-minutowego wysiłku na FTP z użyciem stałego współczynnika może być obarczone błędem i zależy silnie od indywidualnego profilu wydolności oraz poziomu zmęczenia zawodnika (Inglis i in., 2020; Jeffries i in., 2021). Co więcej, etykieta ta może pochodzić z fragmentu jazdy niebędącego formalnym testem, co oznacza różny kontekst jej zarejestrowania (np. wyścig, podjazd). Prace dotyczące relacji między FTP, maksymalnym stanem równowagi mleczanowej (MLSS) oraz mocą krytyczną (CP) pokazują, że wielkości te zależą od przyjętej metodologii badania i nie powinny być utożsamiane (Caen i in., 2024). Ograniczenie to dotyczy zarówno zbioru treningowego, jak i testowego, gdyż modele były ewaluowane względem tej samej operacyjnej definicji.

Drugie ograniczenie dotyczy data leakage. Wariant A pokazał, że uwzględnienie `mmp_20min` prowadzi do odtworzenia zależności arytmetycznej. W wariancie B cechę tę usunięto, ale pozostałe cechy MMP nadal wymagają ostrożnej interpretacji. Z tego względu dodatkowo przygotowano wariant C.

Trzecia grupa ograniczeń wynika z terenowego charakteru danych, które pochodzą z różnorodnych urządzeń pomiarowych. Różnice w jakości sensorów, błędy kalibracji, przerwy w transmisji czy zmienne warunki środowiskowe wpływają na

stabilność cech wejściowych. Zgodnie z literaturą metrologiczną ocena mierników mocy powinna uwzględniać nie tylko ich nominalną dokładność, lecz przede wszystkim powtarzalność i odporność na czynniki zewnętrzne (Bouillod i in., 2022), co jest szczególnie istotne przy stosowaniu urządzeń jednostronnych opierających się na założeniu pełnej symetrii pracy kończyn (Valenzuela i in., 2022).

Nie każdy brak lub nietypowa wartość ma to samo znaczenie. Zerowa moc może odpowiadać zjazdowi, toczeniu roweru lub chwilowemu brakowi aktywnego pedałowania. Brak tętna może wynikać z niezłożenia czujnika albo utraty sygnału. Zmiana wysokości i prędkości może być zaburzona przez jakość GPS. Agregacja cech ogranicza wpływ części zakłóceń, ale nie usuwa wszystkich problemów. W systemie wdrożeniowym potrzebny byłby dodatkowy mechanizm oceny jakości konkretnej sesji i możliwość pominięcia predykcji, jeżeli dane są niewystarczające.

Historyczny charakter repozytorium ogranicza również wiedzę o kontekście aktywności. Dane nie muszą zawierać pełnej informacji o stanie zdrowia, zmęczeniu, warunkach pogodowych, sprzęcie ani celu treningu. Model może wykorzystywać regularności występujące w zgromadzonym zbiorze, ale nie wszystkie z nich muszą utrzymać się po zmianie populacji użytkowników lub sposobu rejestracji. Jest to typowe ryzyko przenoszenia modelu z danych historycznych do bieżącego zastosowania.

Czwarte ograniczenie dotyczy walidacji opartej wyłącznie na historycznym zbiorze GoldenCheetah z osobniczym podziałem na dane treningowe i testowe. Oznacza to, że wyniki nie zostały zweryfikowane w sposób prospektywny ani na zewnętrznym zbiorze danych, co wyklucza bezpośrednie przeniesienie rozwiązania do zastosowań produkcyjnych. Choć podział osobniczy (*subject-wise split*) chroni przed wyciekiem informacji tożsamościowej kolarzy, nie eliminuje on wpływu niestacjonarności danych oraz zależności czasowych.

Ewaluacja zdolności modelu do generalizacji na nieznanym wcześniej sportowców różni się od walidacji czasowej. W praktycznym systemie treningowym kluczowe byłoby prognozowanie przyszłych wartości FTP na podstawie przeszłych aktywności danej osoby, co wymagałoby wdrożenia schematu walidacji krokowej (*walk-forward validation*). Jak wskazuje literatura dotycząca szeregów czasowych, niestacjonarność oraz autokorelacja w danych telemetrycznych wymuszają ostrożny dobór procedury podziału prób w celu uniknięcia optymistycznego obciążenia metryk

(Bergmeir i in., 2018). Analiza ta stanowi naturalne rozszerzenie przedstawionego potoku badawczego.

Ograniczeniem pozostaje brak pogłębionej analizy błędów z rozbiem według zawodnika, liczby dostępnych sesji, kompletności sensorów oraz profilu zawodnika. W rozdziale eksperymentalnym uzupełniono podstawowe rozwarstwienie według zakresu referencyjnej etykiety FTP, ale jest to dopiero pierwszy krok audytu: najwyższy przedział obejmuje niewielką liczbę sesji i zawodników, a analiza nie wyjaśnia przyczyn błędów na poziomie konkretnych przypadków. Metryki zagregowane opisują ogólny poziom jakości, ale nie pozwalają jednoznacznie wskazać wszystkich grup, dla których model działa najslabiej. Przed wdrożeniem należałoby przeprowadzić audyt takich grup i określić warunki, w których system powinien wstrzymać estymację. Dodatkowo, ocena dokładności za pomocą Mean Absolute Error (MAE) wyrażonego w watach ma charakter wyłącznie bezwzględny, przez co jej praktyczne znaczenie jest silnie zdeterminowane poziomem wydolności danego zawodnika.

4.5. Praktyczne możliwości zastosowania

Opracowany system może stanowić podstawę modułu analitycznego wspierającego trening. Potencjalne scenariusze obejmują:

- prezentowanie trendu estymowanego FTP w aplikacji treningowej;
- sygnalizowanie potrzeby aktualizacji stref mocy;
- wspomaganie trenera w analizie historii treningów zawodnika;
- porównywanie estymacji pasywnej z wynikiem okresowo wykonywanego testu referencyjnego.

Każdy z tych scenariuszy wymaga dodatkowej walidacji oraz jasnego komunikowania niepewności predykcji. Szczególnie istotne jest unikanie automatycznych rekomendacji opartych wyłącznie na pojedynczym wyniku modelu.

4.5.1. Koncepcja modułu wspierającego platformę treningową

W zastosowaniu produkcyjnym model mógłby działać jako wydzielony moduł analityczny zintegrowany z platformą treningową lub aplikacją mobilną. Moduł taki przetwarzałby dane sesji po jej zakończeniu i synchronizacji z urządzeniem

rejestrującym. Na podstawie zagregowanych cech telemetrycznych generowałby sugerowaną wartość FTP, prezentowaną użytkownikowi jako orientacyjny wskaźnik dyspozycji wytrzymałościowej, a nie jako oficjalny wynik testu.

Od strony technicznej moduł predykcyjny mógłby zostać udostępniony przez interfejs API backendu aplikacji. Nowe aktywności byłyby cyklicznie kierowane do potoku ekstrakcji cech, a wynik estymacji zapisywany wraz z informacją o wersji modelu i jakości danych wejściowych. Eksploatacja rozwiązania wymagałaby monitorowania błędów względem okresowych testów referencyjnych, obserwacji dryfu rozkładu cech oraz rekaliibracji modelu po zgromadzeniu nowszych danych.

Kluczowym elementem interfejsu powinna być informacja o niepewności wyniku. Moduł powinien komunikować, z jakim przybliżeniem operuje estymacja — na przykład poprzez podanie zakresu wartości lub poziomu ufności. Uwzględniając uzyskane wyniki eksperymentalne (gdzie średni błąd MAE wynosił ok. 6,55 W dla wariantu B oraz ok. 10,29 W dla wariantu C), przedział ten powinien odzwierciedlać realny margines niepewności modelu. Jeżeli dane wejściowe są niekompletne (brak sygnału tętna, nietypowo krótka sesja, duża liczba zerowych wartości mocy), moduł powinien obniżyć ocenę wiarygodności predykcji albo wstrzymać się od jej prezentacji. Tego rodzaju mechanizm oceny jakości danych na poziomie pojedynczej sesji jest niezbędny, aby użytkownik nie traktował każdego wyniku jako jednakowo pewnego.

Moduł nie powinien automatycznie zastępować testów kontrolnych ani samodzielnie aktualizować stref treningowych. W docelowym scenariuszu estymacja pasywna pełni rolę uzupełniającą: sygnalizuje potencjalne zmiany formy, wskazuje moment, w którym warto rozważyć test referencyjny, oraz umożliwia obserwację trendu pomiędzy formalnymi pomiarami. Automatyczne modyfikowanie stref na podstawie pojedynczej predykcji wiązałoby się z ryzykiem błędnego dostosowania obciążeń treningowych, co mogłoby prowadzić zarówno do przeciążenia (przy zawyżonej estymacji), jak i do ograniczenia bodźca treningowego (przy zaniżonej).

Wdrożenie powinno przebiegać etapami. W fazie pilotażowej moduł mógłby działać w trybie wyłącznie informacyjnym, prezentując sugerowane FTP obok wyniku ostatniego testu referencyjnego. Dopiero po zebraniu danych porównawczych z wielu użytkowników i okresów treningowych uzasadnione byłoby rozszerzenie funkcjonalności o rekomendacje dotyczące aktualizacji stref. Na każdym etapie

użytkownik powinien mieć możliwość odrzucenia lub zignorowania sugestii modelu.

4.5.2. Perspektywa zawodnika

Dla zawodnika najważniejsza jest użyteczność informacji w codziennym treningu. Estymacja może pokazywać trend FTP i sygnalizować, że strefy mocy wymagają sprawdzenia. Jeżeli wartość rośnie stopniowo w kilku kolejnych obserwacjach, może to uzasadniać zaplanowanie testu kontrolnego. Analogicznie spadek może skłonić do analizy regeneracji, obciążeń lub jakości danych. Model nie powinien jednak automatycznie zmieniać stref na podstawie pojedynczej sesji, ponieważ na wynik mogą wpływać warunki trasy i chwilowa dyspozycja.

Prezentacja dla użytkownika powinna być prosta, ale nie pozbawiona kontekstu. Obok estymowanej wartości potrzebna jest informacja, z jakiego okresu i ilu aktywności skorzystano, czy dane z czujników były kompletne oraz jak stabilny jest ostatni trend. Użytkownik powinien wiedzieć, że wynik jest przybliżeniem wspierającym decyzję, a nie odpowiednikiem laboratoryjnego pomiaru.

4.5.3. Perspektywa trenera

Trener może traktować estymację jako dodatkowy sygnał uzupełniający historię obciążeń, samopoczucie zawodnika i wyniki formalnych testów. W pracy z większą liczbą podopiecznych szczególnie wartościowe może być wskazywanie przypadków wymagających uwagi: wyraźnej zmiany trendu, rozbieżności pomiędzy estymacją a ostatnim testem albo pogorszenia jakości danych. Takie zastosowanie nie zastępuje interpretacji eksperckiej, lecz pomaga kierować uwagę na sesje i zawodników, których warto przeanalizować dokładniej.

Trener powinien również rozróżniać warianty modelu. Wariant B daje niższy błąd, a konserwatywny wariant C może pełnić rolę dodatkowego punktu odniesienia. Rozbieżność obu estymacji sygnalizowałaby potrzebę ostrożniejszej interpretacji.

4.5.4. Perspektywa platformy analitycznej

Platforma analityczna może łączyć model z kontrolą jakości i historią użytkownika. Powinna wyliczać predykcję dla sesji spełniających minimalne warunki kompletności, wygładzać krótkookresowe wahania oraz obserwować zmiany rozkładu danych, które mogą wpływać na jakość modelu.

4.6. Ryzyka wdrożenia i komunikowanie niepewności

Automatyczna estymacja FTP wiąże się z ryzykiem nadmiernego zaufania do pojedynczej liczby. Zawyżona predykcja może prowadzić do ustawienia zbyt intensywnych stref i zwiększenia obciążenia treningowego. Zaniżona może ograniczać bodziec treningowy albo maskować rzeczywistą poprawę formy. Ryzyko jest większe, gdy użytkownik nie widzi informacji o jakości danych i traktuje model jako bezbłędny pomiar.

Interfejs powinien uzupełniać wartość FTP zakresem orientacyjnym, oceną kompletności sygnałów oraz informacją o stabilności estymacji. W przypadku braku tętna, małej liczby aktywności albo nietypowego przebiegu danych system może oznaczyć wynik jako mniej wiarygodny lub wstrzymać rekomendację.

Niepewność dotyczy również samej etykiety. Model może bardzo dobrze odtwarzać historyczne `ftp_label`, ale wartość ta pozostaje heurystycznym przybliżeniem FTP. Dlatego w zastosowaniu praktycznym potrzebny jest cykl kontroli: pasywna estymacja wspiera obserwację trendu, okresowy test weryfikuje punkt odniesienia, a rozbieżności prowadzą do analizy danych zamiast automatycznego rozstrzygnięcia.

Zasadne byłoby wdrażanie rozwiązania etapami. W pierwszej kolejności model mógłby działać w trybie informacyjnym, bez automatycznej zmiany stref treningowych. Dopiero porównanie estymacji z okresowymi testami referencyjnymi pozwoliłoby ocenić, w jakich warunkach rekomendacja jest wystarczająco stabilna.

Zakończenie

Niniejsza praca miała na celu zaprojektowanie, implementację oraz ewaluację prototypowego systemu analitycznego służącego do estymacji operacyjnej etykiety Functional Threshold Power (FTP) na podstawie danych telemetrycznych z treningów kolarskich.

FTP jest praktycznym, ale uproszczonym wskaźnikiem wydolności kolarskiej. Tradycyjne testy terenowe i diagnostyka laboratoryjna dostarczają wartościowych informacji, lecz są obciążające, kosztowne lub trudne do częstego powtarzania. Dane telemetryczne rejestrowane podczas rutynowych treningów tworzą natomiast podstawę do częstszej estymacji operacyjnej etykiety FTP z wykorzystaniem modeli regresyjnych. Warunkiem rzetelnej oceny jest kontrola jakości danych oraz ryzyka wycieku informacji.

Część teoretyczna wykazała również, że FTP nie powinno być utożsamiane bezpośrednio z mocą krytyczną, maksymalnym stanem równowagi mleczanowej ani progami mleczanowymi i wentylacyjnymi. Pojęcia te opisują powiązane aspekty wydolności, ale wynikają z odmiennych definicji i protokołów. Także współczynnik 0,95 stosowany do przeliczenia próby 20-minutowej ma charakter heurystyczny. Model przybliży zatem operacyjną etykietę FTP, a nie zastępuje pełnej diagnostyki fizjologicznej.

W ramach pracy przygotowano potok przetwarzania danych obejmujący ekstrakcję, filtrację i inżynierię cech. Finalny zbiór eksperymentalny obejmował 151 399 sesji treningowych 726 zawodników, przygotowanych na podstawie 781 archiwów ZIP.

Zbudowano trzy warianty eksperymentalne. Wariant A, zawierający `mmp_20min`, ujawnił ryzyko data leakage i pełnił wyłącznie funkcję kontrolną. Główny wariant badawczy B po usunięciu `mmp_20min` uzyskał wysoką jakość predykcji; najlepszy model XGBoost osiągnął $MAE = 6,55$ W, $RMSE = 9,68$ W oraz $R^2 = 0,9630$. Konserwatywny wariant C, pozbawiony wszystkich cech `mmp_*`, osiągnął wyższy błąd, ale nadal pozwalał odtworzyć znaczną część wariancji etykiety FTP.

Znaczenie części empirycznej nie sprowadza się do wyboru najlepszego algorytmu. Porównanie wariantów pokazało, jak silnie wynik może zależeć od pochodzenia predyktorów. Podział po `athlete_id` ograniczył dodatkowo ryzyko, że

model będzie oceniany na sesjach osób częściowo znanych z treningu. Otrzymane metryki odnoszą się więc do zawodników nieobecnych w zbiorze uczącym, ale nadal pozostają wynikiem historycznej ewaluacji na jednym repozytorium danych.

Przyjęta hipoteza badawcza zakładała, że co najmniej jeden model wariantu C, pozbawionego wszystkich cech `mmp_*`, osiągnie na danych zawodników nieobecnych w zbiorze uczącym MAE nie większe niż 15 W oraz R^2 nie mniejsze niż 0,80. Najlepszy model XGBoost uzyskał MAE = 10,29 W i $R^2 = 0,9170$, dlatego oba kryteria zostały spełnione i hipotezę przyjęto w granicach zastosowanej operacjonalizacji. Wynik dotyczy historycznych danych GoldenCheetah OpenData oraz heurystycznej etykiety FTP; nie potwierdza równoważności z testem laboratoryjnym ani gotowości systemu do wdrożenia bez walidacji prospektywnej.

Ostrożność jest szczególnie istotna w odniesieniu do słowa „pasywne”. W głównym wariancie B usunięto bezpośrednią cechę etykietującą, ale pozostawiono inne statystyki MMP. Wariant C pokazuje rezultat bardziej rygorystyczny, uzyskany bez całej grupy `mmp_*`. Oba warianty są potrzebne: pierwszy odpowiada głównemu scenariuszowi badawczemu, a drugi określa jakość możliwą do utrzymania przy konserwatywnym ograniczeniu cech.

Odpowiedzi na pytania badawcze są spójne z tą oceną. Modele bez cechy `mmp_20min` zachowały wysoką jakość predykcji dla zawodników nieobecnych w zbiorze treningowym, choć wynik odnosi się do etykiety heurystycznej. W eksperymencie bazowym najwyższą jakość w wariancie B osiągnął XGBoost, przy bardzo zbliżonym wyniku Random Forest. Analiza ważności cech i SHAP wskazała, że w wariancie B kluczowe znaczenie mają sąsiadujące cechy MMP, natomiast w wariancie C większą rolę przejmują kwantyle mocy, średnia moc, rozkład intensywności oraz relacja mocy do tętna. Wariant A pokazał natomiast, że pozostawienie `mmp_20min` prowadzi do sztucznie zawyżonych metryk, dlatego pełni funkcję diagnostyczną, a nie stanowi dowodu jakości modelu.

Opracowany system może stanowić podstawę narzędzia wspomagającego analizę trendu FTP, ocenę potrzeby aktualizacji stref treningowych oraz pracę trenera z historią aktywności zawodnika. Predykcja powinna być traktowana jako informacja pomocnicza i interpretowana łącznie z kontekstem treningowym oraz jakością danych z sensorów. Aktualizacja stref treningowych na podstawie modelu powinna być

traktowana jako rekomendacja wymagająca weryfikacji, a nie jako automatyczna decyzja systemu.

Praktyczna wartość pracy polega również na przygotowaniu powtarzalnego procesu prowadzącego od surowej telemetrii do ocenianej predykcji. Prototyp może być punktem wyjścia dla modułu analitycznego, który nie zastępuje decyzji zawodnika lub trenera, lecz ułatwia wskazanie momentu wymagającego dokładniejszej oceny formy. Kluczowe jest przy tym pamiętać, że zmienna celu ma charakter operacyjny i heurystyczny: model estymuje przyjętą etykietę FTP obliczoną z przelicznika 0,95, a nie laboratoryjnie zmierzony próg fizjologiczny. Wynik predykcji nie powinien być zatem traktowany jako równoważnik pełnej diagnostyki wydolnościowej.

Najważniejsze ograniczenia wynikają ze sposobu utworzenia etykiety, terenowej jakości danych, historycznego charakteru zbioru i braku walidacji zewnętrznej. Kolejne etapy prac powinny zatem obejmować walidację prospektywną, pełniejszy audyt etykiet FTP, ocenę na niezależnym zbiorze testowym oraz analizę błędów dla różnych profili zawodników. Warto również porównać podejście oparte na cechach zagregowanych z modelowaniem sekwencyjnym surowych szeregów czasowych.

Uzupełnieniem może być personalizacja modelu po zgromadzeniu historii nowego zawodnika oraz okresowych testów referencyjnych. Wymaga to osobnego eksperymentu sprawdzającego, czy dostosowanie do osoby poprawia jakość bez utraty odporności na błędy i zmianę warunków treningowych. Dopiero po walidacji prospektywnej, audycie etykiet oraz sprawdzeniu modelu na niezależnych danych zasadne będzie formułowanie dalej idących wniosków wdrożeniowych.

Bibliografia

Pozycje zwarte

1. Allen, Hunter, Andrew R. Coggan i Stephen McGregor (2019). *Training and Racing with a Power Meter*. 3 wyd. VeloPress. ISBN: 9781937715939.
2. Hastie, Trevor, Robert Tibshirani i Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2 wyd. Springer. ISBN: 9780387848570.
3. James, Gareth, Daniela Witten, Trevor Hastie i Robert Tibshirani (2021). *An Introduction to Statistical Learning: with Applications in R*. 2 wyd. Springer. ISBN: 9781071614174.

Artykuły naukowe i materiały konferencyjne

4. Ashfaq, Atiqa, Neil Cronin i Philipp Müller (2022). „Recent Advances in Machine Learning for Maximal Oxygen Uptake (VO₂max) Prediction: A Review”. W: *Informatics in Medicine Unlocked*. DOI: 10.1016/j.imu.2022.100863.
5. Bergmeir, Christoph, Rob J. Hyndman i Bonsoo Koo (2018). „A Note on the Validity of Cross-Validation for Evaluating Autoregressive Time Series Prediction”. W: *Computational Statistics & Data Analysis* 120, s. 70–83. DOI: 10.1016/j.csda.2017.11.003.
6. Bernett, Judith, David B. Blumenthal, Dominik G. Grimm, Florian Haselbeck, Roman Joeres, Olga V. Kalinina, Markus List i in. (2024). „Guiding Questions to Avoid Data Leakage in Biological Machine Learning Applications”. W: *Nature Methods* 21, s. 1444–1453. DOI: 10.1038/s41592-024-02362-y.
7. Borszcz, Franciszek K., Alexandre F. Tramontin, Adriano H. Bossi, Luiz J. Carminatti, Vitor P. Costa, Marcos D. Limana i Ricardo D. de Lucas (2018). „Functional Threshold Power in Cyclists: Validity of the Concept and Physiological Responses”. W: *International Journal of Sports Medicine* 39.10, s. 737–742. DOI: 10.1055/s-0044-101546.
8. Borszcz, Franciszek K., Alexandre F. Tramontin, Kaylly M. de Souza, Luiz J. Carminatti i Vitor P. Costa (2019). „Is the Functional Threshold

- Power Interchangeable With the Maximal Lactate Steady State in Trained Cyclists?” W: *International Journal of Sports Physiology and Performance*. DOI: 10.1123/ijsp.2018-0572.
9. Bouillod, Anthony, Georges Soto-Romero, Frédéric Grappe, William Bertucci, Emmanuel Brunet i Johan Cassirame (2022). „Caveats and Recommendations to Assess the Validity and Reliability of Cycling Power Meters: A Systematic Scoping Review”. W: *Sensors* 22.1, s. 386. DOI: 10.3390/s22010386.
 10. Breiman, Leo (2001). „Random Forests”. W: *Machine Learning* 45.1, s. 5–32. DOI: 10.1023/A:1010933404324.
 11. Caen, Kevin, Jan G. Bourgois, Eline Stassijns i Jan Boone (2024). „Critical Power and Maximal Lactate Steady State in Cycling: ‘Watts’ the Difference?” W: *Sports Medicine*. DOI: 10.1007/s40279-024-02075-4.
 12. Chai, Tianfeng i Roland R. Draxler (2014). „Root Mean Square Error (RMSE) or Mean Absolute Error (MAE)? Arguments Against Avoiding RMSE in the Literature”. W: *Geoscientific Model Development* 7.3, s. 1247–1250. DOI: 10.5194/gmd-7-1247-2014.
 13. Chaibub Neto, Elias, Abhishek Pratap, Thanneer M. Perumal, Meghasyam Tummalacherla, Phil Snyder, Brian M. Bot, Andrew D. Trister, Stephen H. Friend, Lara Mangravite i Larsson Omberg (2019). „Detecting the Impact of Subject Characteristics on Machine Learning-Based Diagnostic Applications”. W: *npj Digital Medicine* 2, s. 99. DOI: 10.1038/s41746-019-0178-x.
 14. Chorley, Alan i Kevin L. Lamb (2020). „The Application of Critical Power, the Work Capacity above Critical Power (W'), and Its Reconstitution: A Narrative Review of Current Evidence and Implications for Cycling Training Prescription”. W: *Sports* 8.9, s. 123. DOI: 10.3390/sports8090123.
 15. Denham, Joshua, John Scott-Hamilton, Amanda D. Hagstrom i Adrian J. Gray (2020). „Cycling Power Outputs Predict Functional Threshold Power and Maximum Oxygen Uptake”. W: *Journal of Strength and Conditioning Research* 34.12, s. 3489–3497. DOI: 10.1519/JSC.0000000000002253.

16. Dong, Qizheng (2022). „Leakage Prediction in Machine Learning Models When Using Data from Sports Wearable Sensors”. W: *Computational Intelligence and Neuroscience* 2022, s. 5314671. DOI: 10.1155/2022/5314671.
17. Fuller, Daniel, Reed Ferber i Kevin Stanley (2022). „Why Machine Learning (ML) Has Failed Physical Activity Research and How We Can Improve”. W: *BMJ Open Sport & Exercise Medicine* 8.1, e001259. DOI: 10.1136/bmjsem-2021-001259.
18. Galán-Rioja, Miguel Ángel, Fernando González-Mohíno, David C. Poole i José María González-Ravé (2020). „Relative Proximity of Critical Power and Metabolic/Ventilatory Thresholds: Systematic Review and Meta-Analysis”. W: *Sports Medicine* 50.10, s. 1771–1783. DOI: 10.1007/s40279-020-01314-8.
19. Gavin, Timothy P., Jeffrey B. Van Meter, Patrick M. Brophy, Gabriel S. Dubis, Kevin N. Potts i Robert C. Hickner (2012). „Comparison of a Field-Based Test to Estimate Functional Threshold Power and Power Output at Lactate Threshold”. W: *Journal of Strength and Conditioning Research* 26.2, s. 416–421. DOI: 10.1519/JSC.0b013e318220b4eb.
20. Gough, Lewis A., Benjamin Dobson, Jake J. Williams, Gregory Downes, Savannah Sturridge, Ashley Warner, S. Andy Sparks i Daniel Brown (2025). „The Reliability and Construct Validity of the Functional Threshold Power Test in Trained Cyclists”. W: *Journal of Science and Cycling* 14.1, 6. DOI: 10.28985/1425.jsc.06.
21. Hoerl, Arthur E. i Robert W. Kennard (1970). „Ridge Regression: Biased Estimation for Nonorthogonal Problems”. W: *Technometrics* 12.1, s. 55–67. DOI: 10.1080/00401706.1970.10488634.
22. Inglis, Erin C., Danilo Iannetta, Louis Passfield i Juan M. Murias (2020). „Maximal Lactate Steady State Versus the 20-Minute Functional Threshold Power Test in Well-Trained Individuals: ‘Watts’ the Big Deal?” W: *International Journal of Sports Physiology and Performance*. DOI: 10.1123/ijsp.2019-0214.
23. Jeffries, Owen, Rachel Simmons, Stephen D. Patterson i Mark Waldron (2021). „Functional Threshold Power Is Not Equivalent to Lactate Parameters in Trained Cyclists”. W: *Journal of Strength and Conditioning Research* 35.10, s. 2790–2794. DOI: 10.1519/JSC.0000000000003203.

24. Jones, Andrew M., Mark Burnley, Matthew I. Black, David C. Poole i Anni Vanhatalo (2019). „The Maximal Metabolic Steady State: Redefining the ‘Gold Standard’”. W: *Physiological Reports* 7.10, e14098. DOI: 10.14814/phy2.14098.
25. Karsten, Bettina, Luca Petrigna, Andreas Klose, Antonino Bianco, Nathan Townsend i Christoph Triska (2021). „Relationship Between the Critical Power Test and a 20-min Functional Threshold Power Test in Cycling”. W: *Frontiers in Physiology* 11, s. 613151. DOI: 10.3389/fphys.2020.613151.
26. Kaufman, Shachar, Saharon Rosset, Claudia Perlich i Ori Stitelman (2012). „Leakage in Data Mining: Formulation, Detection, and Avoidance”. W: *ACM Transactions on Knowledge Discovery from Data* 6.4, 15:1–15:21. DOI: 10.1145/2382577.2382579.
27. McGrath, Eanna, Nick Mahony, Neil Fleming, Conor Raleigh i Bernard Donne (2021). „Do Critical and Functional Threshold Powers Equate in Highly Trained Athletes?” W: *International Journal of Exercise Science* 14.4, s. 45–59.
28. Pedregosa, Fabian, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot i Édouard Duchesnay (2011). „Scikit-Learn: Machine Learning in Python”. W: *Journal of Machine Learning Research* 12, s. 2825–2830.
29. Pinot, Julien i Frédéric Grappe (2011). „The Record Power Profile to Assess Performance in Elite Cyclists”. W: *International Journal of Sports Medicine* 32.11, s. 839–844. DOI: 10.1055/s-0031-1279773.
30. Richter, Chris, Martin O'Reilly i Eamonn Delahunt (2021). „Machine Learning in Sports Science: Challenges and Opportunities”. W: *Sports Biomechanics*. DOI: 10.1080/14763141.2021.1910334.
31. Rosenblatt, Matthew, Link Tejavibulya, Rongtao Jiang, Stephanie Noble i Linda C. Mayes (2024). „Data Leakage Inflates Prediction Performance in Connectome-Based Machine Learning Models”. W: *Nature Communications* 15, s. 1829. DOI: 10.1038/s41467-024-46150-w.

32. Rossi, Alessio, Luca Pappalardo i Paolo Cintia (2022). „A Narrative Review for a Machine Learning Application in Sports: An Example Based on Injury Forecasting in Soccer”. W: *Sports* 10.1, s. 5. DOI: 10.3390/sports10010005.
33. Saeb, Sohrab, Luca Lonini, Arun Jayaraman, David C. Mohr i Konrad P. Kording (2017). „The Need to Approximate the Use-Case in Clinical Machine Learning”. W: *GigaScience* 6.5, s. 1–9. DOI: 10.1093/gigascience/gix019.
34. Sitko, Sebastian, Rafel Cirer-Sastre, Francisco Corbi i Isaac López-Laval (2022). „Time to exhaustion at estimated functional threshold power in cyclists with different performance levels”. W: *Journal of Science and Medicine in Sport* 25.1, s. 79–84. DOI: 10.1016/j.jsams.2021.08.016.
35. Sitko, Sebastian, Rafel Cirer-Sastre i Isaac López-Laval (2023). „An Update of the Allen & Coggan Equation to Predict 60-min Power Output in Cyclists of Different Performance Levels”. W: *International Journal of Sports Medicine* 44.13, s. 983–987. DOI: 10.1055/a-2079-1363. URL: <https://doi.org/10.1055/a-2079-1363>.
36. Stessens, Loes, Jasper Gielen, Romain Meeusen i Jean-Marie Aerts (2024). „Physical Performance Estimation in Practice: A Systematic Review of Advancements in Performance Prediction and Modeling in Cycling”. W: *International Journal of Sports Science & Coaching* 19.5. DOI: 10.1177/17479541241262385.
37. Tougui, Ilias, Abdelilah Jilbab i Jamal El Mhamdi (2021). „Impact of the Choice of Cross-Validation Techniques on the Results of Machine Learning-Based Diagnostic Applications”. W: *Healthcare Informatics Research* 27.3, s. 189–199. DOI: 10.4258/hir.2021.27.3.189.
38. Valenzuela, Pedro L., Almudena Montalvo-Pérez, Lidia B. Alejo, Mario Castellanos, Jaime Gil-Cabrera, Eduardo Talavera, Alejandro Lucia i David Barranco-Gil (2022). „Are Unilateral Devices Valid for Power Output Determination in Cycling? Insights From the Favero Assioma Power Meter”. W: *International Journal of Sports Physiology and Performance* 17.3, s. 484–488. DOI: 10.1123/ijsp.2021-0278.
39. Vos, Luuk, Renske N. Vergeer, Richie P. Goulding, Guido Weide, Jos J. de Koning, Richard T. Jaspers i Stephan van der Zwaard (2025). „Predicting Cycling

- Performance Before and After Training: Insights From Machine Learning Using Small Samples”. W: *Applied Artificial Intelligence* 39.1. DOI: 10.1080/08839514.2025.2565167.
40. Chen, Tianqi i Carlos Guestrin (2016). „XGBoost: A Scalable Tree Boosting System”. W: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, s. 785–794. DOI: 10.1145/2939672.2939785.
 41. Karetnikov, Aleksei, Wim Nuijten i Marwan Hassani (2021). „Data-Driven Support of Coaches in Professional Cycling Using Race Performance Prediction”. W: *Proceedings of the 9th International Conference on Sport Sciences Research and Technology Support (icSPORTS 2021)*. SCITEPRESS, s. 43–53. DOI: 10.5220/0010656300003059.
 42. Kohavi, Ron (1995). „A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection”. W: *Proceedings of the 14th International Joint Conference on Artificial Intelligence – Volume 2*. Morgan Kaufmann Publishers Inc., s. 1137–1143.
 43. Luder, Victor, Sizhen Bian i Michele Magno (2024). „CycloWatt: An Affordable, TinyML-enhanced IoT Device Revolutionizing Cycling Power Metrics”. W: *2024 IEEE International Instrumentation and Measurement Technology Conference (I2MTC)*. DOI: 10.1109/I2MTC60896.2024.10560804.
 44. Lundberg, Scott M. i Su-In Lee (2017). „A Unified Approach to Interpreting Model Predictions”. W: *Advances in Neural Information Processing Systems* 30, s. 4765–4774.
 45. Stockwell, Martin i Frank Corradini (2023). „A Machine Learning Approach to Predict Cyclists’ Functional Threshold Power”. W: *Intelligent Data Engineering and Automated Learning – IDEAL 2023*. Springer. DOI: 10.1007/978-3-031-48232-8_34.

Netografia

1. BikeRadar (2023). *Training with Heart Rate vs Training with Power: Which Is Best for You?* URL: <https://www.bikeradar.com/advice/fitness-and-training/power-vs-heart-rate> [dostęp: 01.06.2026].
2. Nomad Frontiers (2026). *Power vs Heart Rate: Which Training Zones Make Faster Cyclists?* URL: <https://nomadfrontiers.ca/cycling/training/power-vs-heart-rate-training-zones/> [dostęp: 01.06.2026].
3. Phases Cycling (2023). *Functional Threshold Power: Useful? Or Simply Too Variable?* URL: <https://phasescycling.com/2023/10/30/functional-threshold-power-useful-or-simply-too-variable/> [dostęp: 01.06.2026].
4. scikit-learn developers (2026). *sklearn.model_selection.GroupKFold — scikit-learn Documentation*. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html [dostęp: 01.06.2026].
5. Kaggle (redlineracer) (2020). *Road Cycling Performance Testing – Power Output, Blood Lactate, and Heart Rate Data from Maximal Performance Tests*. URL: <https://www.kaggle.com/datasets/redlineracer/roady-cycling-performance-testing> [dostęp: 01.06.2026].
6. Liversedge, Mark (2020). *GoldenCheetah OpenData Project*. Open Science Framework. DOI: 10.17605/OSF.IO/6HFPZ. URL: <https://osf.io/6hfpz/> [dostęp: 01.06.2026].

Spis rysunków

1.1	Dryf tętna przy stałej mocy	15
1.2	Schemat przebiegu testu 20-minutowego FTP	17
1.3	Schemat przebiegu testu 60-minutowego FTP	19
1.4	Przykładowa krzywa mocy	20
2.1	Schemat architektury potoku analitycznego	35
2.2	Przykładowe profile mocy względem czasu trwania wysiłku	40
2.3	Porównanie losowego podziału sesji i podziału osobniczego	44
3.1	Porównanie wartości MAE między wariantami i modelami	53
3.2	Porównanie współczynnika determinacji między wariantami i modelami	54
3.3	Rzeczywiste i przewidywane wartości FTP dla modelu XGBoost	55
3.4	Rozkład błędów modelu XGBoost w wariancie B	56
3.5	Ważność cech modelu XGBoost w wariancie B	57
3.6	Ważność cech modelu XGBoost w wariancie C	58
3.7	Wykres beeswarm SHAP dla modelu XGBoost w wariancie C	59
3.8	Ranking cech SHAP wariantu C w próbie kontrolnej	63
3.9	Porównanie eksperymentu bazowego i próby kontrolnej	64
3.10	Wartości rzeczywiste i przewidywane FTP w próbie kontrolnej	65
3.11	Rozkład błędów predykcji FTP w próbie kontrolnej	65

Spis tabel

2.1	Przykładowy zanonimizowany fragment zapisu telemetrycznego aktywności po eksporcie do postaci tabelarycznej.	37
3.1	Struktura przygotowanego zbioru danych wykorzystanego w eksperymentach	48
3.2	Podział danych na zbiór treningowy i testowy	49
3.3	Konfiguracja modeli wykorzystanych w eksperymencie	50
3.4	Zbiorcze wyniki predykcji FTP na zbiorze testowym dla wariantów A, B i C	51
3.5	Błędy predykcji modelu XGBoost w wariancie B według zakresów referencyjnej etykiety FTP	55
3.6	Porównanie skali eksperymentu bazowego i próby kontrolnej	61
3.7	Porównanie najważniejszych cech według średnich bezwzględnych wartości SHAP dla modelu XGBoost w wariancie C na zbiorze bazowym oraz próbie kontrolnej 5000 archiwów ZIP	62